



(12) 发明专利

(10) 授权公告号 CN 121543600 B

(45) 授权公告日 2026. 05. 08

(21) 申请号 202610071079.X

(22) 申请日 2026.01.20

(65) 同一申请的已公布的文献号

申请公布号 CN 121543600 A

(43) 申请公布日 2026.02.17

(73) 专利权人 天津财经大学

地址 300000 天津市河西区珠江道25号

(72) 发明人 刘婷婷 刁衡

(74) 专利代理机构 天津合正知识产权代理有限公司

公司 12229

专利代理师 石熠

(51) Int.Cl.

G06F 40/35 (2020.01)

G06F 40/216 (2020.01)

G06N 20/00 (2019.01)

G06F 40/242 (2020.01)

G06F 40/166 (2020.01)

G06F 16/35 (2025.01)

G06F 40/284 (2020.01)

(56) 对比文件

CN 114139528 A, 2022.03.04

CN 119940359 A, 2025.05.06

审查员 崔英秀


权利要求书3页 说明书13页 附图2页

(54) 发明名称

面向对外财经话语的智能分析及文本优化方法与系统

(57) 摘要

本发明提供一种面向对外财经话语的智能分析及文本优化方法与系统,属于信息技术与自然语言处理的交叉领域,包括:采集英文财经新闻语料进行预处理并入库,形成英文财经新闻数据库;训练基于机器学习的语言特征标注模型进行语言特征标注,识别英文文本的语言特征;搭建财经话语分析框架,以维度分值和语言特征千词化频次作为财经话语分析框架的分析基础;训练对外财经话语垂域大模型,基于财经话语分析框架对英文财经新闻文本进行分析并提出优化建议。本发明实现对英文财经文本的精准标注、语言特征分析与高质量文本润色,有效提升财经文本在英文母语读者中的可读性、准确性与影响力。



1. 一种面向对外财经话语的智能分析及文本优化方法,其特征在于,包括:

S1、核心数据采集和清洗:采集国外媒体英文财经新闻语料以及国内外宣媒体英文财经新闻语料,进行预处理并入库,形成英文财经新闻数据库;

S2、训练语言特征标注模型:基于机器学习方法,进行三轮模型训练,第一轮模型训练识别包含词性、简单语法和词汇立场的语言特征,第二轮模型训练识别包含复杂语法的语言特征,第三轮模型训练进行迭代改进,最终得到英文文本语言特征标注模型;

S3、搭建财经话语分析框架:计算语言特征的千词化频次,通过因子分析得到若干个维度,以各维度分值及语言特征的标准化频次作为财经话语分析框架的分析基础,用于计算与待分析文本之间的欧式距离;包括:

S301、使用所述语言特征标注模型对英文财经新闻数据库的英文文本进行重新标注,得到包含全部语言特征的标注结果;

S302、计算全部语言特征在每条英文文本数据中的千词化频次,计算方式为:语言特征千词化频次=(语言特征实际频次/文本总token数)*1000;

S303、将所有语言特征的千词化频次导入社会科学统计软件SPSS中进行因子分析,删除载荷值低于0.35的语言特征,形成若干特征维度,每一维度下包含若干有明显共现趋势的语言特征;

S304、统计同一维度下的语言特征在关键句中中共现的分布情况,通过对分布情况的观察,最终确定各个维度的具体分类命名;

S305、抽样形成维度命名验证数据集,将语言特征划分到对应的维度中,进行定量检验和定性评估;所述定量检验包括在维度命名验证数据集上对每个维度计算其载荷特征的方差解释率与克隆巴赫系数,并检验维度间的相关系数;随后将维度命名验证数据集按投影后的维度得分做聚类,评估维度得分在区分文本差异上的有效性;所述定性评估包括审阅每个维度对应的高载荷特征列表,并挑选其中出现的典型句子,判断这些句子是否与维度命名所暗示的语义范畴相符;若句子与命名契合,确认命名合理;若出现不匹配,则需重新调整特征归属或命名;

S306、以所述语言特征的千词化频次作为标准化频次,并计算各维度分值,计算公式为:维度分值=(该维度下所有正向特征千词化频次总和-该维度下所有负向特征千词化频次总和);根据各语言特征标准化频次和各维度分值形成英文财经话语评价标准,用于与待分析文本进行对比并形成分析结果;

S4、训练对外财经话语垂域大模型:使用开源大模型作为基座进行微调,使其掌握步骤S1-S3中的知识,获得智能化交互的对外财经话语垂域大模型,为提升英文财经文本质量提供优化建议。

2. 根据权利要求1所述的面向对外财经话语的智能分析及文本优化方法,其特征在于,步骤S1中所述预处理的方法包括:

S101、去重:通过正则表达式筛选存在重复可能性的英文财经新闻语料,基于文本内容的相似度计算进行去重;

S102、数据筛选:通过正则表达式找到存在连续大写的文本,判断是否存在格式不规范或内容质量低的问题以及是否需要剔除。

3. 根据权利要求1所述的面向对外财经话语的智能分析及文本优化方法,其特征在于,

步骤S1中在预处理后、入库前,需要进行数据标准化和清洗,包括:标题格式调整;提取专有名词,形成专有名词词典;对正文内容大小写、标点符号、常见缩写形式、句首字母大写进行标准化处理;对文本进行清洗,去除包括非法字符或网址链接的无关内容,并对清洗后的标题和正文进行词形还原。

4. 根据权利要求1所述的面向对外财经话语的智能分析及文本优化方法,其特征在于,步骤S1中所述入库包括:对文本内容进行分割,分出标题、日期、来源、水印信息、正文;构建数据库,分为ID、标题、清洗后的标题、水印、来源、日期、正文、清洗后的正文8个字段;将分割后的内容写入相应的字段,每条数据有唯一的ID,形成英文财经新闻数据库;通过微调LDA主题聚类模型,对英文财经新闻数据库中清洗后的文本和标题进行多次聚类,形成若干个一、二、三级主题。

5. 根据权利要求1所述的面向对外财经话语的智能分析及文本优化方法,其特征在于,步骤S2中语言特征标注模型的第一轮训练包括:

S201、应用词性标注工具对所述英文文本内容进行“一次标注”,标注出每个单词的基础词性标签;

S202、基于所述基础词性标签,结合英文的语法规则,编程对涉及的单词进行“二次标注”,标注出语法特征标签;

S203、根据英文中的立场词汇以及对应类型从句语法规则,编程判断该词汇是否表达立场,如果“是”则对该立场词汇进行“三次标注”,标注出立场标签;

S204、将经过三次标注后形成的数据集分为训练集A、A的验证集、测试集B;

S205、使用RoBERTa-Large作为基座模型对训练集A进行标注训练,使用A的验证集检验每个学习轮次的学习效果,通过测试集B对模型性能进行测试,得到DDU Tagger 1.0语言特征标注模型。

6. 根据权利要求5所述的面向对外财经话语的智能分析及文本优化方法,其特征在于,步骤S205具体包括:使用RobertaTokenizerFast将句子拆成WordPiece子词,并将每个单词的首子词作为一个token,映射到单词对应的标签;随后把标注训练任务分配给RobertaForTokenClassification,通过交叉熵损失让模型在大规模语料上学习如何预测规则标签,训练过程中采用梯度累积、混合精度以及学习率warm-up以适应RoBERTa-Large的显存需求;最终训练得到DDU Tagger 1.0语言特征标注模型。

7. 根据权利要求5所述的面向对外财经话语的智能分析及文本优化方法,其特征在于,步骤S2中语言特征标注模型的第二轮训练包括:

S211、对所述英文文本中当前无法准确标注的包含复杂语法的语言特征进行自主编码,用于复杂语法特征标签的标注;

S212、将不同英文语法词典电子版转为可检索文本,导入数据库;通过索引、归类,形成不同批次的原始例句;使用DDU Tagger 1.0对所述不同批次的原始例句进行预标注,预留待标注项进行复杂语言特征的标注;同一种语言特征的所有批次标注完毕作为一个子数据集,重复此过程生成子数据集C1、C2、C3、...、Cn,n为语言特征的种类数量,所有子数据集共同形成完整数据集C,并预留10%作为测试集D;

S213、使用所述DDU Tagger 1.0语言特征标注模型作为初始权重,使用数据集C对其进行训练,得到DDU Tagger 2.0语言特征标注模型。

8. 根据权利要求5所述的面向对外财经话语的智能分析及文本优化方法,其特征在于,步骤S2中语言特征标注模型的第三轮训练包括:

使用DDU Tagger 2.0语言特征标注模型对第一轮训练中使用的测试集B再次执行标注,统计标签正确和错误情况,检验模型标注准确率;针对高错误率标签进行迭代改进;随后把所有错误实例及新增标注合并成最终训练集E,并在此基础上以DDU Tagger 2.0语言特征标注模型为初始权重进行再训练,直至宏平均F1 ≥ 0.92 、各新标签召回率 ≥ 0.80 且整体准确率 $\geq 98\%$,得到最终的语言特征标注模型DDU Tagger 3.0。

9. 一种面向对外财经话语的智能分析及文本优化系统,其特征在于,包括:

顺序连接的核心数据采集和清洗层、语言特征标注模型训练层、财经话语分析框架模块和对外财经话语垂域大模型;

核心数据采集和清洗层:采集国外媒体英文财经新闻语料以及国内外宣媒体英文财经新闻语料,进行预处理并入库,形成英文财经新闻数据库;

语言特征标注模型训练层:基于机器学习方法,进行三轮模型训练,第一轮模型训练识别包含词性、简单语法和词汇立场的语言特征,第二轮模型训练识别包含复杂语法的语言特征,第三轮模型训练进行迭代改进,最终得到英文文本语言特征标注模型;

财经话语分析框架模块:计算语言特征的千词化频次,通过因子分析得到若干个维度,以各维度分值及语言特征的标准化频次作为财经话语分析框架的分析基础,用于计算与待分析文本之间的欧式距离;包括:使用所述语言特征标注模型对英文财经新闻数据库的英文文本进行重新标注,得到包含全部语言特征的标注结果;计算全部语言特征在每条英文文本数据中的千词化频次,计算方式为:语言特征千词化频次=(语言特征实际频次/文本总token数)*1000;将所有语言特征的千词化频次导入社会科学统计软件SPSS中进行因子分析,删除载荷值低于0.35的语言特征,形成若干特征维度,每一维度下包含若干有明显共现趋势的语言特征;统计同一维度下的语言特征在关键句中出现的分布情况,通过对分布情况的观察,最终确定各个维度的具体分类命名;抽样形成维度命名验证数据集,将语言特征划分到对应的维度中,进行定量检验和定性评估;所述定量检验包括在维度命名验证数据集上对每个维度计算其载荷特征的方差解释率与克隆巴赫系数,并检验维度间的相关系数;随后将维度命名验证数据集按投影后的维度得分做聚类,评估维度得分在区分文本差异上的有效性;所述定性评估包括审阅每个维度对应的高载荷特征列表,并挑选其中出现的典型句子,判断这些句子是否与维度命名所暗示的语义范畴相符;若句子与命名契合,确认命名合理;若出现不匹配,则需重新调整特征归属或命名;以所述语言特征的千词化频次作为标准化频次,并计算各维度分值,计算公式为:维度分值=(该维度下所有正向特征千词化频次总和-该维度下所有负向特征千词化频次总和);根据各语言特征标准化频次和各维度分值形成英文财经话语评价标准,用于与待分析文本进行对比并形成分析结果;

对外财经话语垂域大模型:使用开源大模型作为基座进行微调,使其掌握核心数据采集和清洗层、语言特征标注模型训练层、财经话语分析框架模块的知识,获得智能化交互的对外财经话语垂域大模型,为提升英文财经文本质量提供优化建议。

面向对外财经话语的智能分析及文本优化方法与系统

技术领域

[0001] 本发明属于信息技术与自然语言处理的交叉领域,具体涉及一种面向对外财经话语的智能分析及文本优化方法与系统。

背景技术

[0002] 现有的英文文本分析优化方法或系统,仅聚焦于单纯的英文词性或语法分析,应用于对外财经话语,多数存在技术短板,例如:

[0003] (1) 无法通过财经语域下的语言特征共现性分析对英文财经话语表述进行精准评价。

[0004] (2) 无法对英文财经话语中的立场表达进行精准定位和系统分析。

[0005] (3) 无法通过与自训练大模型的智能化交互,得到专业的英文财经话语优化建议和真实语域中的相关例句展示。

[0006] 综上所述,现有的英文文本分析优化方法或系统,难以实现对英文财经文本的精准标注、语言特征解析与高质量文本润色,很难提升财经文本在英文母语读者中的可读性、准确性与影响力。

发明内容

[0007] 本发明的目的在于提供一种面向对外财经话语的智能分析及文本优化方法与系统,结合机器学习技术与统计分析方法,构建英文财经话语评价体系,实现对财经文本的分析、评估与改进。

[0008] 为了实现上述目的,本发明的技术方案是这样的:

[0009] 一种面向对外财经话语的智能分析及文本优化方法,包括:

[0010] S1、核心数据采集和清洗:采集国外媒体英文财经新闻语料以及国内外宣媒体英文财经新闻语料,进行预处理并入库,形成英文财经新闻数据库;

[0011] S2、训练语言特征标注模型:基于机器学习方法,进行三轮模型训练,第一轮模型训练识别包含词性、简单语法和词汇立场的语言特征,第二轮模型训练识别包含复杂语法的语言特征,第三轮模型训练进行迭代改进,最终得到英文文本语言特征标注模型;

[0012] S3、搭建财经话语分析框架:计算语言特征的千词化频次,通过因子分析得到若干个维度,以各个维度标准分值及语言特征的标准化频次作为财经话语分析框架的分析基础,用于计算与待分析文本之间的欧式距离;

[0013] S4、训练对外财经话语垂域大模型:使用开源大模型作为基座进行微调,使其掌握步骤S1-S3中的知识,获得智能化交互的对外财经话语垂域大模型,为提升英文财经文本质量提供优化建议。

[0014] 进一步的,步骤S1中所述预处理的方法包括:

[0015] S101、去重:通过正则表达式筛选存在重复可能性的英文财经新闻语料,基于文本内容的相似度计算进行去重;

[0016] S102、数据筛选:通过正则表达式找到存在连续大写的文本,判断是否存在格式不规范或内容质量低的问题以及是否需要剔除。

[0017] 进一步的,步骤S1中在预处理后、入库前,需要进行数据标准化和清洗,包括:标题格式调整;提取专有名词,形成专有名词词典;对正文内容大小写、标点符号、常见缩写形式、句首字母大写进行标准化处理;对文本进行清洗,去除包括非法字符或网址链接的无关内容,并对清洗后的标题和正文进行词形还原。

[0018] 进一步的,步骤S1中所述入库包括:对文本内容进行分割,分出标题、日期、来源、水印信息、正文;构建数据库,分为ID、标题、清洗后的标题、水印、来源、日期、正文、清洗后的正文8个字段;将分割后的内容写入相应的字段,每条数据有唯一的ID,形成英文财经新闻数据库;通过微调LDA主题聚类模型,对英文财经新闻数据库中清洗后的文本和标题进行多次聚类,形成若干个一、二、三级主题。

[0019] 进一步的,步骤S2中语言特征标注模型的第一轮训练包括:

[0020] S201、应用词性标注工具对所述英文文本内容进行“一次标注”,标注出每个单词的基础词性标签;

[0021] S202、基于所述基础词性标签,结合英文的语法规则,编程对涉及的单词进行“二次标注”,标注出语法特征标签;

[0022] S203、根据英文中的立场词汇以及对应类型从句语法规则,编程判断该词汇是否表达立场,如果“是”则对该立场词汇进行“三次标注”,标注出立场标签;

[0023] S204、将经过三次标注后形成的数据集分为训练集A、A的验证集、测试集B;

[0024] S205、使用RoBERTa-Large作为基座模型对训练集A进行标注训练,使用A的验证集检验每个学习轮次的学习效果,通过测试集B对模型性能进行测试,得到DDU Tagger 1.0语言特征标注模型。

[0025] 更进一步的,步骤S205具体包括:使用RobertaTokenizerFast将句子拆成WordPiece子词,并将每个单词的首子词作为一个token,映射到单词对应的标签;随后把标注训练任务分配给RobertaForTokenClassification,通过交叉熵损失让模型在大规模语料上学习如何预测规则标签,训练过程中采用梯度累积、混合精度以及学习率warmup以适应RoBERTaLarge的显存需求;最终训练得到DDU Tagger 1.0语言特征标注模型。

[0026] 更进一步的,步骤S2中语言特征标注模型的第二轮训练包括:

[0027] S211、对所述英文文本中当前无法准确标注的复杂语言特征进行自主编码,用于复杂语法特征标签的标注;

[0028] S212、将不同英文语法词典电子版转为可检索文本,导入数据库;通过索引、归类,形成不同批次的原始例句;使用DDU Tagger 1.0对所述不同批次的原始例句进行预标注,预留待标注项进行复杂语言特征的标注;同一种语言特征的所有批次标注完毕作为一个子数据集,重复此过程生成子数据集C1、C2、C3、...、Cn,n为语言特征的种类数量,所有子数据集共同形成完整数据集C,并预留10%作为测试集D;

[0029] S213、使用所述DDU Tagger 1.0语言特征标注模型作为初始权重,使用数据集C对其进行训练,得到DDU Tagger 2.0语言特征标注模型。

[0030] 更进一步的,步骤S2中语言特征标注模型的第三轮训练包括:

[0031] 使用DDU Tagger 2.0语言特征标注模型对第一轮训练中使用的测试集B再次执行

标注,统计标签正确和错误情况,检验模型标注准确率;针对高错误率标签进行迭代改进;随后把所有错误实例及新增标注合并成最终训练集E,并在此基础上以DDU Tagger 2.0语言特征标注模型为初始权重进行再训练,直至宏平均F1 ≥ 0.92 、各新标签召回率 ≥ 0.80 且整体准确率 $\geq 98\%$,得到最终的语言特征标注模型DDU Tagger 3.0。

[0032] 进一步的,步骤S3具体包括:

[0033] S301、使用所述语言特征标注模型对英文财经新闻数据库的英文文本进行重新标注,得到包含全部语言特征的标注结果;

[0034] S302、计算全部语言特征在每条英文文本数据中的千词化频次,计算方式为:语言特征千词化频次=(语言特征实际频次/文本总token数)*1000;

[0035] S303、将所有语言特征的千词化频次导入社会科学统计软件SPSS中进行因子分析,删除载荷值低于0.35的语言特征,形成若干特征维度,每一维度下包含若干有明显共现趋势的语言特征;

[0036] S304、统计同一维度下的语言特征在关键句中出现的分布情况,通过对分布情况的观察,最终确定各个维度的具体分类命名;

[0037] S305、抽样形成维度命名验证数据集,将语言特征划分到对应的维度中,进行定量检验和定性评估;所述定量检验包括在维度命名验证数据集上对每个维度计算其载荷特征的方差解释率与克隆巴赫系数,并检验维度间的相关系数;随后将维度命名验证数据集按投影后的维度得分做聚类,评估维度得分在区分文本差异上的有效性;所述定性评估包括审阅每个维度对应的高载荷特征列表,并挑选其中出现的典型句子,判断这些句子是否与维度命名所暗示的语义范畴相符;若大部分句子与命名契合,确认命名合理;若出现显著不匹配,则需重新调整特征归属或命名;

[0038] S306、以所述语言特征的千词化频次作为标准化频次,并计算各维度的标准分值,计算公式为:维度分值=(该维度下所有正向特征千词化频次总和-该维度下所有负向特征千词化频次总和);根据各语言特征标准化频次和各维度的标准分值形成英文财经话语评价标准,用于与待分析文本进行对比并形成分析结果。

[0039] 本发明另一方面还提出了一种面向对外财经话语的智能分析及文本优化系统,包括:

[0040] 顺序连接的核心数据采集和清洗层、语言特征标注模型训练层、财经话语分析框架模块和对外财经话语垂域大模型;

[0041] 核心数据采集和清洗层:采集国外媒体英文财经新闻语料以及国内外宣媒体英文财经新闻语料,进行预处理并入库,形成英文财经新闻数据库;

[0042] 语言特征标注模型训练层:基于机器学习方法,进行三轮模型训练,第一轮模型训练识别包含词性、简单语法和词汇立场的语言特征,第二轮模型训练识别包含复杂语法的语言特征,第三轮模型训练进行迭代改进,最终得到英文文本语言特征标注模型;

[0043] 财经话语分析框架模块:计算语言特征的千词化频次,通过因子分析得到若干个维度,以各个维度标准分值及语言特征的标准化频次作为财经话语分析框架的分析基础,用于计算与待分析文本之间的欧式距离;

[0044] 对外财经话语垂域大模型:使用开源大模型作为基座进行微调,使其掌握核心数据采集和清洗层、语言特征标注模型训练层、财经话语分析框架模块的知识,获得智能化交

互的对外财经话语垂域大模型,为提升英文财经文本质量提供优化建议。

[0045] 与现有技术相比,本发明具有如下的有益效果:

[0046] 1、本发明构建的英文语言特征标注方法、话语分析框架和财经话语分析垂域大模型,能够实现对英文财经文本的精准标注、语言特征分析与高质量文本润色。

[0047] 2、本发明可以为对外财经新闻相关英文文本的编辑工作提供全流程支持:涵盖数据清洗、词性及句法等语言特征的提取,主题、观点、立场的识别,以及文本解析、评估和改进等多个环节。

[0048] 3、本发明有效提升财经新闻在英文母语读者中的可读性、准确性与影响力。

附图说明

[0049] 图1为本发明实施例1的方法流程示意图;

[0050] 图2为本发明实施例2的系统架构示意图。

具体实施方式

[0051] 需要说明的是,在不冲突的情况下,本发明中的实施例及实施例中的特征可以相互组合。

[0052] 下面结合具体实施例和附图,对本发明进行具体说明。

[0053] 实施例1:

[0054] 本实施例应用本发明的面向对外财经话语的智能分析及文本优化方法,其中很多步骤都是通过编程语言进行编程实现自动化操作,本实施例中以python为优选,使用了python的编程功能,但并非仅局限于python,使用其他编程语言实现同样功能也均属于本发明的保护范围。

[0055] 如图1所示,面向对外财经话语的智能分析及文本优化方法具体包括:

[0056] 一、核心数据采集和清洗。

[0057] 1.1 数据采集:采集英美主流媒体的英文财经新闻语料、中国主要外宣媒体的英文财经新闻语料,含标题、正文、日期、来源、作者等数据。

[0058] 1.2 数据预处理:对原始文本进行系统的预处理,具体包括:

[0059] 1.2.1 去重,剔除重复的文本。

[0060] (1) 提取标题前缀并分组:

[0061] 通过Python正则表达式 PREFIX_SEPARATOR从文件首行标题中提取前缀;按提取的前缀对文件分组,统计每个分组的文件数量、唯一标题数;目的是快速缩小比对范围,把内容可能相关的文件归为一类,避免全量文件两两比对的低效问题。

[0062] 仅保留文件数大于1的分组作为候选去重对象;进一步筛选出“无子类”(分组内所有文件标题完全相同)且文件数 $\leq$ SIMILARITY_GROUP_MAX_SIZE(默认10)的分组,仅对这类分组进行后续内容比对。其中保留文件数大于1的分组,是为了只聚焦有重复可能性的对象,单个文件无去重必要,直接过滤可减少后续处理负荷;筛选“无子类”分组是因为标题完全一致的文件,内容重复概率极高,优先针对这类组处理,能大幅提升去重命中率;限制文件数 $\leq$ 10的目的是平衡去重效率和覆盖度,过多文件(如超过10个)的内容比对会增加计算成本,10个以内既能覆盖多数重复场景,又能保证处理速度。

[0063] (2) 双规则并行的相似度匹配:

[0064] 计算文档内容的完整相似度(standard ratio),若大于等于设定的阈值0.8,则判定为相似,标记“Standard”类型;当标准相似度不达标时,取较长内容与较短内容的前N个字符(N=较短内容长度)进行比对,计算子集相似度(subset_ratio),若子集相似度大于等于设定的阈值0.9,则判定为相似,标记为Subeset类型;删除匹配到的相似度高于阈值的文本,只保留其中一份。

[0065] 1.2.2 数据筛选,剔除质量较低或主题不相关的文本。

[0066] (1) 通过上一步找到的有子类新闻标题,以关键词作为筛选条件,例如可以通过startswith语句查找以某关键词XX开头的新闻,然后通过抽样查看新闻内容判断某子类下的新闻是否需要批量剔除;

[0067] (2) 通过正则表达式VALID_WORD_REGEX和MULTI_WORD_PATTERN分别找到标题和正文中连续大写的部分这些文章可能存在格式不规范或内容质量低的问题,通过人工判断是否需要剔除。

[0068] 1.3 数据清洗:

[0069] 包括:标题格式调整;提取专有名词,形成专有名词词典;通过Python编写文本格式处理程序对正文内容大小写、标点符号、常见缩写形式、句首字母大写等进行标准化处理;应用Python的自然语言处理工具包NLTK和Python正则表达式,对文本进行清洗,去除非法字符、网址链接等无关内容,并应用自然语言处理库Spacy对清洗后的标题和正文进行词形还原。

[0070] 1.4 数据入库:

[0071] 包括:通过正则表达式对文本内容进行分割,分出标题、日期、来源、水印信息、正文几个部分;构建PostgreSQL数据库,分为ID、标题、清洗后的标题、水印、来源、日期、正文、清洗后的正文8个字段;将分割后的内容写入相应的字段,每条数据有唯一的ID,形成英文财经新闻数据库 α ;通过微调LDA主题聚类模型,对英文财经新闻数据库 α 中清洗后的文本和标题进行多次聚类,形成若干个一、二、三级主题。

[0072] 二、训练语言特征标注模型。

[0073] 本实施例使用RoBERTa-Large (RoBERTa模型的最大参数版本) 作为基座模型进行标注训练。

[0074] RoBERTa是Facebook AI Research推出的一种基于BERT优化的预训练模型,在BERT的基础上,通过对预训练流程的优化,显著提升了模型性能。RoBERTa 通过在大规模语料库上进行预训练,学习到了丰富的语言知识和语义表示,能够准确理解文本的含义,捕捉文本中的语法、语义和上下文信息,由于预训练阶段已经积累了大量的通用语言知识,所以在微调时,即使只有少量的特定任务标注数据,模型也能利用这些数据进行有效的学习和调整,从而获得较为准确的标注结果。

[0075] 2.1、第一轮训练:

[0076] 第一轮训练主要针对包括词性、简单语法、词汇立场的语言特征的标注。

[0077] 2.1.1应用词性标注工具Stanford POS Tagger对数据库中的英美财经新闻文本进行“一次标注”,得到每个单词的基础词性标签,格式例如:“I will be a teacher.”这句话,标注基础词性标签后为“I_PRP will_MD be_VB a_teacher_NN.”,PRP代表人称代词;MD

代表情态动词;VB代表动词原形;NN代表可数或不可数的普通名词;通过上述基础词性标签可以识别部分语言特征。

[0078] 2.1.2结合上述基础词性标签和英文语法知识,使用Python语言编写基于规则的“二次标注”程序,对文本进行标注,主要是针对特征明显,能转换成规则判断且准确率较高的语法标注,得到语法特征标签。以“I will be a teacher.”这句话为例,标注后为:“ I_FP will_MOD be_COP a_DT teacher_NN.”,其中FP代表第一人称代词;MOD代表情态动词,与“一次标注”中的情态动词标签MD不同的是,MOD属于句法依存关系(Dependency Relation)体系中的标签,描述情态动词与后续动词之间的语法关系;COP代表系动词;DT代表限定词;NN代表单数名词;通过上述语法特征标签可以识别针对语法方面的部分语言特征。

[0079] 所述特征明显,能转换成规则判断且准确率较高的语法,可以理解为容易识别的英文语法规则,能够用编程实现其规则判断。例如,COP是系动词,其判断方式的实现如下:

[0080] (1) 定义一个系动词候选集合,包含be动词的所有形式及seem、appear、feel、look、become等动词;同时定义一个形容词例外集合,包含常用作形容词的分词,如tired、interested、exciting、boring等;

[0081] (2) 检查句子中出现系动词候选词的位置(索引为j),如果其右侧至多2个位置内(不能有除了引号外的其他标点符号)出现VBN或VBG标签的单词,并且该VBN或VBG的词干存在于形容词例外集合中,则将j标记为COP;

[0082] (3) 如果在位置j的候选词右侧至多2个位置内出现的VBN或VBG不满足规则2的条件,则进一步判断该分词是否为VBG且其右侧紧邻的是除引号外的标点符号,如果是,则将j标记为COP;

[0083] (4) 定义一个prep集合,如果在位置j的候选词右侧至多2个位置内没有VBN或VBG,但其紧邻的右侧位置的词性是名词(N开头)、形容词(JJ开头)或介词(pre集合中的词),则将j标记为COP。

[0084] (5) 如果一个系动词候选词不满足上述规则中的任何一条,则该词不被标记为COP。

[0085] 如上例的特征明显,能转换成规则判断且准确率较高的语法,都在“二次标注”中实现标注。对于特征不明显、不易准确标注的复杂语法特征,在后续第二轮训练中实现标注。

[0086] 2.1.3基于一次标注的基础词性标签和二次标注的语法标签,结合Stanford Pos Tagger和英文语法知识,使用Python语言编写基于规则的“三次标注”程序,并对文本进行标注,得到立场标签。

[0087] 英文语言的立场是通过特定的立场词汇表达的,大体上分为立场动词、立场名词、立场形容词,但是并非只要出现该词汇就认为是表达立场的词汇,需要结合语法规则进行判断,例如立场动词/形容词/名词 + to/that 从句,属于立场表达的一种形式,可以对其制定相应的判断规则,符合该规则且在立场词汇表中的词汇,可判断认为其表达一定的语言立场。其具体表达的立场类型,根据其在立场词汇表的分类确定。

[0088] 本实施例中所述立场词汇表,由现有的英文中的立场词汇及其同义词、近义词汇总而成,并通过词性、以及补语从句的类型进行分类。

[0089] 仍以“I will be a teacher.”这句话为例,标注后为:“I_FP will_MOD [PRSM] be_COP a_DT teacher_NN.”,其中增加的PRSM就是一个立场标签,代表表达预测/意志立场的情态动词。通过上述立场标签可以识别语言立场方面的部分语言特征。

[0090] 三次标注完成后,得到标准JSON格式的英文财经新闻标注数据集,其中包含句子、每轮标注的词汇标签、时间戳、句子索引、新闻日期、新闻来源、类型等信息,将全量数据集分割为三部分:80%为训练集A,10%为A的验证集,10%为测试集B。验证集用于检测模型每个训练轮次的学习效果,方便对参数进行调优。

[0091] 2.1.4将训练集A作为RoBERTaLarge模型训练的数据来源,让模型对标注结果进行学习。

[0092] 使用基于RoBERTa模型的高性能分词器RobertaTokenizerFast将句子拆成WordPiece子词,并把每个单词的首子词作为代表该单词的token,映射到该单词对应的标签,后续子词被设为忽略(-100)。RobertaTokenizerFast使用的是一种叫做子词(Subword)的分词方法,而WordPiece是实现这种子词分词的一种具体算法,核心思想在于平衡词汇表大小和对未知词的处理能力。不同于简单地按空格切分,WordPiece会从一个庞大的语料库中学习,将文本分解为有意义的子词单元。对于像“unbelievably”这样的复杂词,它不会将其视为一个无法识别的未知词,而是可能将其拆分成“un”、“believe”和“##ably”等更常见、更有意义的片段。其中,“##”这样的前缀标志着这个子词片段是一个词的后续部分,而不是一个独立的词的开始,这帮助模型理解词的内部结构。也正因为一个完整的词可能会被拆分成多个子词,所以在进行序列标注任务时,才需要将标签映射到首个子词上,并忽略后续子词,以确保每个原始单词只被评估一次,主要是为了避免重复计算带来的性能问题。

[0093] 随后把标注训练任务分配给基于RoBERTa模型的序列标注任务模型RobertaForTokenClassification,通过交叉熵损失让模型在大规模语料上学习如何预测规则标签,交叉熵损失(Cross Entropy)在单标签任务中只需把每个 token 的真实标签映射为整数ID,并在模型输出的logits(模型在最后一层产生的原始、未经归一化的分数)上用nn.CrossEntropyLoss(单标签分类损失函数)计算;通过设置 ignore_index=-100 让损失loss自动忽略 padding(padding 是在 NLP 任务中把不同长度的句子/序列统一到同一长度的做法,在实际训练时,模型一次只能处理固定长度的张量批次(也就是一个batch),于是在每个较短句子后面补齐“占位符”——PAD token,使得整个 batch 的形状一致)和子词;对于多标签任务,需要将每个token的标签编码为0/1的多热向量,使用nn.BCEWithLogitsLoss(多标签分类损失函数),同样通过mask过滤掉padding(用一个掩码mask把句子中填充padding位置标记出来,并在需要的计算步骤,如loss、注意力、词向量聚合等中将这此位置排除掉);在训练时,可将loss除以梯度累积步数,配合混合精度和 warm up调度(warm up即在训练初期,先用非常小的学习率,让模型慢慢适应梯度;随后逐步把学习率提升到目标值,再按预设策略衰减),确保显存使用与学习率变化最优。

[0094] 训练过程中采用梯度累积、混合精度以及学习率warmup以适应 RoBERTaLarge的显存需求。在训练模型时先把批次拆成若干子批(梯度累积),每个子批先用 autocast() 开启混合精度,模型前向得到logits后用CrossEntropyLoss(单标签)或BCEWithLogitsLoss(多标签)计算损失,然后把损失除以累积步数再反向传播;等到累积步数完成后再调用optimizer.step()(optimizer 是“梯度更新器”,把梯度信息转化为实际

的参数变动,从而让模型逐步逼近最优解)并把梯度归零;同时使用学习率warm up,先用线性或余弦调度器在前10% 的总步数里将学习率从0逐渐提升到目标值,随后在剩余步数里按预设策略衰减。这样既能节省显存、提升训练速度,又能在训练早期稳定模型。

[0095] 最终,微调后的模型能够针对测试集中的句子生成与预期一致的标注结果,实现从已有知识向模型的传递。

[0096] 2.1.5使用测试集B对模型性能进行测试,用微调好的RoBERTaLarge进行一次完整推理,得到每个token的预测标签。随后与标注好的数据集标签进行对比,统计总体准确率、宏/微平均F1、以及每个标签的精确率与召回率,判断模型在语言特征方面的迁移效果,针对识别准确率较低的标签再次投放新的数据集训练,直至模型标注准确率与训练集相近($\approx 98\%$),认为该语言特征标注模型第一轮训练完毕,暂命名为DDU Tagger 1.0。

[0097] 2.2、第二轮训练:

[0098] 第一轮训练主要针对包含复杂语法的语言特征的标注。

[0099] 2.2.1对第一轮训练中无法准确标注的复杂语言特征进行自主编码,所述自主编码是指找到语言特征,并赋予指定的标签。因为某些包含复杂语法的语言特征无法通过编写规则的方式识别,因此需要先通过人工标注得到数据集,然后将数据集投喂给模型训练,最终得到一个基于模型预测的标注器,而不是基于规则的标注器;编码的意义在于后续人工标注的时候对特定的语言特征进行统一的标签,作为复杂语法特征标签,方便第二轮训练中模型对标签进行学习。

[0100] 例如:关系代词(RP) that/which/who/引导限制性定语从句(RAC)_修饰主句主语(S)_作从句主语(S),可编码为[SS-RPRAC],在例句中该编码的使用为:“He that_[SS-RPRAC] would eat the fruit must climb the tree.”。

[0101] 2.2.2获取第二轮训练所需的数据集。

[0102] 首先通过OCR(光学字符识别)将不同英文语法词典电子版转为可检索文本,导入PostgreSQL数据库,供快速检索例句使用;通过检索、归类,形成不同批次的原始例句。

[0103] 其次使用DDU Tagger 1.0对所有不同批次的原始例句进行预标注,会在每个已有规则的token下生成标签,无法准确标注的语言特征标注为0,作为预留的待标注项,可通过人工交叉标注,根据步骤2.2.1的自主编码填写对应的复杂语法特征标签。所述人工交叉标注是指人工标注的过程中,可能出现对于某个复杂语法特征标签识别不准的情况,因此需要多人(至少两人)对同一批次的句子进行交叉标注,标注结果一致则提交数据集,不一致则需要管理员执行最终标注。

[0104] 针对某一种特定的语言特征进行标注,所有批次标注完毕即作为一个子数据集,重复此过程生成 C1、C2、C3...Cn,n为语言特征的种类数量,所有子数据集共同形成完整数据集C,并预留10%作为测试集D。

[0105] 2.2.3使用DDU Tagger 1.0对完整数据集C进行训练(采用梯度累积、混合精度以及学习率warmup),评估宏/微F1、精确率、召回率,对低表现标签做错误分析:

[0106] 当宏平均F1 ≥ 0.92 且所有新标签召回率 ≥ 0.80 时确认模型合格;在测试集D上进行评估,若整体准确率 $\geq 98\%$ 并且新标签F1显著提升,则模型第二轮训练完毕,暂命名为DDU Tagger 2.0。

[0107] 2.3、第三轮训练:

[0108] 2.3.1使用DDU Tagger 2.0对第一轮训练中使用的测试集B再次执行标注,统计标签正确和错误情况,检验模型标注准确率;

[0109] 2.3.2针对标注错误率高的标签,对模型错误进行核对,生成错误标签报告,按错误率、混淆情况、稀有度、语义歧义等维度开展细致误差分析。基于分析结果,针对高错误率标签采用增量收集、数据增强、类别权重调节、标签平滑和规则补充等手段进行迭代改进;随后把所有错误实例及新增标注合并成最终训练集E,并在此基础上以DDU Tagger 2.0为初始权重进行细粒度学习率、梯度累积、混合精度训练,直至宏平均F1 ≥ 0.92 、各新标签召回率 ≥ 0.80 且整体准确率 $\geq 98\%$,模型第三轮训练完毕,得到完整的语言特征标注模型,命名为DDU Tagger 3.0。

[0110] 三、形成财经话语分析框架。

[0111] 3.1、数据重新标注。用DDU Tagger 3.0对英文财经新闻数据库 α 进行重新标注,得到包含全部语言特征的标注结果。

[0112] 3.2、标准化频次计算。计算全部语言特征在英文财经新闻数据库每条数据中的千词化频次,计算方式为:语言特征千词化频次= (语言特征实际频次/总token数)*1000。

[0113] 3.3、因子分析降维。将所有语言特征的千词化频次导入社会科学统计软件包SPSS中进行因子分析,删除载荷值低于0.35的语言特征,形成若干特征维度,每一维度下包含若干有明显共现趋势的语言特征。其中所述明显共现趋势是指共现趋势可观察、可验证、无歧义,不是模糊的偶然关联,而是能通过具体表现确认的强关联。

[0114] 3.4、维度命名。通过Python开发英文财经新闻数据库检索平台,暂命名为DDU Retrieval 1.0,将数据库进行可视化并可调用DDU Tagger 3.0对文章进行分词和标注,自动计算语言特征的千词化频次和维度分值,通过语言特征批量检索关键词,统计同一维度下的语言特征在关键词中共现的分布情况,通过对分布情况的观察,最终确定各个维度的具体分类命名。

[0115] 3.5、检验和评估。将英文财经新闻数据库 α 进行10%的抽样,形成维度命名验证数据集 β ,汇总该数据集的标注结果,并将语言特征划分到对应的维度中,进行定量检验和定性评估。

[0116] 3.5.1定量检验:在 β 数据集上,对每个因子(维度)计算其载荷特征的方差解释率与克隆巴赫系数(Cronbach's Alpha),并检验维度间的相关系数;随后将 β 数据集文本按投影后的维度得分做聚类,评估维度得分在区分文本差异上的有效性。若解释率 $\geq 50\%$, $\alpha \geq 0.70$,维度相关 ≤ 0.40 ,聚类的轮廓系数(Silhouette Coefficient) ≥ 0.3 ,则认为维度结构统计上可靠。

[0117] 3.5.2定性评估。审阅每个维度对应的高载荷特征列表,并挑选其中出现的典型句子。需判断这些句子是否与维度命名所暗示的语义范畴相符;若大部分句子与命名契合,即可确认命名合理;若出现显著不匹配,则需重新调整特征归属或命名。

[0118] 3.6、形成评价标准。以英文财经新闻数据库 α 中的语言特征的千词化频次作为这些语言特征的标准化频次,并计算各维度的标准分值,计算公式为:维度分值= (该维度下所有正向特征千词化频次总和-该维度下所有负向特征千词化频次总和)。根据各语言特征标准化频次和各维度标准分值形成英文财经话语评价标准。对于任何一篇财经新闻文本,先使用DDU Tagger 3.0完成标注,计算每个语言特征的千词化频次,并将语言特征自动

分类至设定好的维度中,计算该文本在各个维度中的分值,并将特征频次和维度分值与标准进行对比,形成分析结果。

[0119] 四、训练对外财经话语垂域大模型。

[0120] 4.1、基座模型:

[0121] 选用开源大模型作为基座模型进行微调,本实施例选用GPT-OSS-120B(GPT-OSS模型的大参数版本),但并不局限于此,其他同类大模型也可选用。将所有的项目代码和文档知识(标注部分仍由DDU Tagger 3.0完成)切分为简短句子或公式,使用GPT-OSS分词器生成专属token,并在词表后段预留200个特殊ID。随后在Transformer的embedding层后新增一个可训练的知识嵌入表Knowledge Embedding Table,为每条知识对应一个ID,并在每层注意力旁增加一个小的MLP适配器,专门处理ID知识,使模型最终掌握该研究的所有知识内容,作为本发明专门训练的英文对外财经话语垂域大模型,暂时命名为INDEP v1,为后续的评价和问答做好准备。

[0122] 4.2:应用场景:

[0123] 4.2.1英文财经新闻话语评价及提升。

[0124] a.用户上传一篇英文财经新闻稿件,对外财经话语垂域大模型INDEP v1调用DDU Tagger 3.0对该英文财经新闻稿件进行分词和标注;

[0125] b.INDEP v1调用DDU Retrieval 1.0中的运算接口,自动计算语言特征的千词化频率和维度分值;

[0126] c.根据新闻内容和计算结果,自动匹配英文财经新闻数据库 α 中主题相关性高的前50篇文章形成临时数据集E,计算该数据集的语言特征千词化频次和维度分值;其中所述英文财经新闻数据库 α 如前所述在建库时已通过微调LDA主题聚类模型,对清洗后的文本和标题进行多次聚类,形成若干个一、二、三级主题,因此可以直接进行主题相关性的匹配;

[0127] d.INDEP v1.0模型计算用户上传语言特征千词化频次和维度分值与临时数据集E的千词化频次和维度分值的相似度,本实施例中实际是通过二者的欧几里得距离的计算实现相似度计算,判断用户在哪些语言特征的使用上可以进行优化,在维度特征上相比临时数据集E的维度特征具有哪些差异,并在英文财经新闻数据库 α 中查找可供参考的例句,呈现给用户,INDEP v1同时调用之前训练好的内置知识库,重新组织语言,为用户提供改进后的句子,并说明二者在语言特征上的差异,为用户提供参考。

[0128] 4.2.2协助用户撰写英文财经新闻稿。

[0129] a.用户在DDU Retrieval 1.0中选择由系统提供的财经领域相关主题,INDEP v1呈现该主题下根据相关度排序后的所有文章,用户可查看具体文章的维度特征、语言特征、立场特征、主要观点、文本摘要等;

[0130] b.用户向INDEP v1提出相关问题,输入提示词,INDEP v1进行分析后回复。

[0131] 本实施例能够实现对英文财经文本的精准标注、语言特征分析与高质量文本润色,为对外财经相关英文文本的编辑工作提供全流程支持,有效提升财经文本在英文母语读者中的可读性、准确性与影响力。

[0132] 实施例2:

[0133] 本实施例提出了一种面向对外财经话语的智能分析及文本优化系统,如图2所示,包括:

[0134] 核心数据采集和清洗层:采集国外媒体英文财经新闻语料以及国内外宣媒体英文财经新闻语料,进行预处理并入库,形成英文财经新闻数据库;

[0135] 语言特征标注模型训练层:基于机器学习方法,进行三轮模型训练,第一轮模型训练识别包含词性、简单语法、语言立场的简单语言特征,第二轮模型训练识别包含复杂语法的复杂语言特征,第三轮模型训练进行迭代改进,得到识别英文文本语言特征的语言特征标注模型;

[0136] 财经话语分析框架模块:计算语言特征的千词化频次,通过因子分析得到若干个维度,以各个维度标准分值及语言特征的标准化频次作为财经话语分析框架的分析基础,用于计算与待分析文本之间的欧式距离;

[0137] 对外财经话语垂域大模型:选用开源大模型作为基座模型进行微调,使其能够调用所述语言特征标注模型,并通过所述财经话语分析框架进行分析计算,最终获得智能化交互的对外财经话语垂域大模型,为提升英文财经文本质量提供优化建议。

[0138] 其中核心数据采集和清洗层包括:

[0139] 财经新闻数据采集模块:采集英美主流媒体的英文财经新闻语料、中国主要外宣媒体的英文财经新闻语料,含标题、正文、日期、来源、作者等数据。

[0140] 数据预处理模块:进行数据预处理,包括去重:通过正则表达式筛选存在重复可能性的英文财经新闻语料,基于文本内容的相似度计算进行去重;数据筛选:通过正则表达式找到存在连续大写的文本,判断是否存在格式不规范或内容质量低的问题以及是否需要剔除;数据标准化和清洗,包括:标题格式调整;提取专有名词,形成专有名词词典;对正文内容大小写、标点符号、常见缩写形式、句首字母大写进行标准化处理;对文本进行清洗,去除包括非法字符或网址链接的无关内容,并对清洗后的标题和正文进行词形还原。

[0141] 英文财经新闻数据库:对文本内容进行分割,分出标题、日期、来源、水印信息、正文;构建数据库,分为ID、标题、清洗后的标题、水印、来源、日期、正文、清洗后的正文8个字段;将分割后的内容写入相应的字段,每条数据有唯一的ID,形成英文财经新闻数据库;通过微调LDA主题聚类模型,对英文财经新闻数据库中清洗后的文本和标题进行多次聚类,形成若干个一、二、三级主题。

[0142] 语言特征标注模型训练层包括:

[0143] 第一轮训练:应用词性标注工具对所述英文文本内容进行“一次标注”,标注出每个单词的基础词性标签;基于所述基础词性标签,根据英文的语法规则,编程对涉及的单词进行“二次标注”,标注出语法特征标签;根据英文中的立场词汇以及立场词汇之后的从句,编程判断该词汇是否进行立场表达,如果是则对该立场词汇进行“三次标注”,标注出立场标签;将经过三次标注后形成的数据集分为训练集A、A的验证集、测试集B;使用RoBERTa-Large作为基座模型对训练集A进行标注训练,过程为使用RobertaTokenizerFast将句子拆成WordPiece子词,并将每个单词的首子词作为一个token,映射到单词对应的标签;随后把标注训练任务分配给RobertaForTokenClassification,通过交叉熵损失让模型在大规模语料上学习如何预测规则标签,训练过程中采用梯度累积、混合精度以及学习率warmup以适应RoBERTaLarge的显存需求;最终训练得到DDU Tagger 1.0语言特征标注模型。通过测试集B对模型性能进行测试。

[0144] 第二轮训练:对所述英文文本中当前无法准确标注的复杂语言特征进行自主编

码,用于复杂语法特征标签的标注;将不同英文语法词典电子版转为可检索文本,导入数据库;通过检索、归类,形成不同批次的原始例句;使用DDU Tagger 1.0对所述不同批次的原始例句进行预标注,预留待标注项进行复杂语法特征标签的标注;同一种语言特征的所有批次标注完毕作为一个子数据集,重复此过程生成子数据集C1、C2、C3...Cn,n为语言特征的种类数量,所有子数据集共同形成完整数据集C,并预留10%作为测试集D;使用所述DDU Tagger 1.0语言特征标注模型对完整数据集C进行训练,得到DDU Tagger 2.0语言特征标注模型。

[0145] 第三轮训练:使用DDU Tagger 2.0语言特征标注模型对第一轮训练中使用的测试集B再次执行标注,统计标签正确和错误情况,检验模型标注准确率;针对高错误率标签进行迭代改进;随后把所有子数据集、错误实例及新增标注合并成最终训练集E,并在此基础上以DDU Tagger 2.0为初始权重进行再训练,直至宏平均F1 ≥ 0.92 、各新标签召回率 ≥ 0.80 且整体准确率 $\geq 98\%$,得到语言特征标注模型DDU Tagger 3.0。

[0146] 财经话语分析框架模块包括:

[0147] 语言特征标注:使用所述语言特征标注模型DDU Tagger 3.0对英文财经新闻数据库的英文文本进行重新标注,得到包含全部语言特征的标注结果;

[0148] 千词化频次计算:计算全部语言特征在每条英文文本数据中的千词化频次,计算方式为:语言特征千词化频次=(语言特征实际频次/总token数)*1000;

[0149] 因子分析降维:将所有语言特征的千词化频次导入社会科学统计软件SPSS中进行因子分析,删除载荷值低于0.35的语言特征,形成若干特征维度,每一维度下包含若干有明显共现趋势的语言特征;其中所述明显共现趋势是指共现趋势可观察、可验证、无歧义,不是模糊的偶然关联,而是能通过具体表现确认的强关联。

[0150] 维度特征分类:统计同一维度下的语言特征在关键句中共现的分布情况。统计方法为调用DDU Tagger 3.0对文章进行分词和标注后,自动计算语言特征的千词化频次和维度分值,通过语言特征批量检索关键句。通过对共现分布情况的观察,最终确定各个维度的具体分类命名;抽样形成维度命名验证数据集,将语言特征划分到对应的维度中,进行定量检验和定性评估;所述定量检验包括在维度命名验证数据集上对每个维度计算其载荷特征的方差解释率与克隆巴赫系数,并检验维度间的相关系数;随后将维度命名验证数据集按投影后的维度得分做聚类,评估维度得分在区分文本差异上的有效性;所述定性评估包括审阅每个维度对应的高载荷特征列表,并挑选其中出现的典型句子,判断这些句子是否与维度命名所暗示的语义范畴相符;若大部分句子与命名契合,确认命名合理;若出现显著不匹配,则需重新调整特征归属或命名;以所述语言特征的千词化频次作为标准化频次,并计算各维度的标准分值,计算公式为:维度分值=(该维度下所有正向特征千词化频次总和-该维度下所有负向特征千词化频次总和);根据各语言特征标准化频次和各维度的标准分值形成英文财经话语评价标准,用于进行对比并形成分析结果。

[0151] 对外财经话语垂域大模型:

[0152] 选用GPT-OSS-120B(GPT-OSS模型的大参数版本)作为基座模型进行微调,将所有的项目代码和文档知识(标注部分仍由DDU Tagger 3.0完成)切分为简短句子或公式,使用GPT-OSS分词器生成专属token,并在词表后段预留200个特殊ID。随后在Transformer的embedding层后新增一个可训练的知识嵌入表Knowledge Embedding Table,为每条知识对

应一个ID,并在每层注意力旁增加一个小的MLP适配器,专门处理ID知识,使模型最终掌握该研究的所有知识内容,作为本发明专门训练的英文对外财经话语垂域大模型,暂时命名为INDEP v1,为后续的评价和问答做好准备。

[0153] 通过Python开发具备上述架构的英文财经新闻数据库检索平台,命名为DDU Retrieval 1.0,提供用户交互界面、基于对外财经话语垂域大模型INDEP v1的智能分析系统、可调用DDU Tagger 3.0语言特征标注模型的网页端标注工具、以及检索英文财经新闻数据库的数据库检索平台。

[0154] 用户上传一篇英文财经新闻稿件,对外财经话语垂域大模型INDEP v1调用DDU Tagger 3.0对该英文财经新闻稿件进行分词和标注;调用DDU Retrieval 1.0中的运算接口,自动计算语言特征的千词化频率和维度分值;根据新闻内容和计算结果,自动匹配英文财经新闻数据库 α 中主题相关性高的前50篇文章形成临时数据集E,计算该数据集的语言特征千词化频次和维度分值;计算用户上传语言特征千词化频次和维度分值与临时数据集E的千词化频次和维度分值的欧几里得距离,判断用户在哪些语言特征的使用上可以进行优化,在维度特征上相比临时数据集E的维度特征具有哪些差异,并在英文财经新闻数据库 α 中查找可供参考的例句,呈现给用户,INDEP v1同时调用之前训练好的内置知识库,重新组织语言,为用户提供改进后的句子,并说明二者在语言特征上的差异,为用户提供参考。

[0155] 本实施例提出的面向对外财经话语的智能分析及文本优化系统,能够实现实施例1所述的面向对外财经话语的智能分析及文本优化方法,具有与实施例1相同的有益技术效果。

[0156] 以上所述实施例仅是本发明的优选实施方式,只是用于帮助理解本申请的方法及其核心思想,本发明的保护范围并不仅局限于上述实施例,凡属于本发明思路下的技术方案均属于本发明的保护范围。应当指出,对于本技术领域的普通技术人员来说,在不脱离本发明原理前提下的若干改进和润饰,这些改进和润饰也应视为本发明的保护范围。




图1




图2