



(12) 发明专利

(10) 授权公告号 CN 121543587 B

(45) 授权公告日 2026. 05. 08

(21) 申请号 202610057958.7

G06F 18/22 (2023.01)

(22) 申请日 2026.01.16

(56) 对比文件

(65) 同一申请的已公布的文献号

CN 110825876 A, 2020.02.21

申请公布号 CN 121543587 A

CN 116662807 A, 2023.08.29

(43) 申请公布日 2026.02.17

审查员 崔英秀

(73) 专利权人 天津财经大学

地址 300000 天津市河西区珠江道25号

(72) 发明人 刘婷婷 刁衡

(74) 专利代理机构 天津合正知识产权代理有限公司 12229

专利代理师 石熠

(51) Int. Cl.

G06F 40/284 (2020.01)

G06F 40/216 (2020.01)

G06F 18/10 (2023.01)


权利要求书3页 说明书16页 附图2页

(54) 发明名称

一种英语文本立场标注方法及系统

(57) 摘要

本发明提供一种英语文本立场标注方法及系统,属于信息技术与自然语言处理的交叉领域,包括:词性预处理:为英语文本的每个词生成词性标签;规则构建:在所述词性标签的基础上制定立场词汇标注规则,编写代码得到基于规则的立场词汇标注器;数据集标注:依据所述基于规则的立场词汇标注器,对已包含词性标签的英语文本进行立场标注,得到立场标注数据集;机器学习训练:使用所述立场标注数据集,以RoBERTa-Large作为基座模型进行训练,得到基于训练的立场词汇标注器,提升标注准确率;立场标注:通过所述基于训练的立场词汇标注器,完成待分析英语文本的立场标注。本发明构建英语文本立场标注器,实现对英语文本立场的精准标注。



1. 一种英语文本立场标注方法,其特征在于,包括:

S1、词性预处理:通过数据采集获得英语文本,为英语文本的每个词生成词性标签;

S2、规则构建:在所述词性标签的基础上,依据英语句法结构、上下文语义及词汇特性,制定立场词汇标注规则,编写代码得到基于规则的立场词汇标注器;立场词汇标注规则的制定包括:

S201、简单立场词汇标注:将情态动词、半情态动词、立场副词作为简单立场词汇,并进行词汇定义扩展;结合目标词的词形与所述词性标签,进行简单立场词汇的判断与标注;

S202、复杂立场词汇标注:将引导补语从句的立场动词、立场形容词、立场名词作为复杂立场词汇;汇总复杂立场词汇的识别类型,设定每种识别类型对应的通用规则和特殊规则;结合目标词的词形与所述词性标签,根据识别类型及其对应规则进行复杂立场词汇的判断与标注;

S3、数据集标注:使用所述基于规则的立场词汇标注器,对已包含词性标签的英语文本进行立场标注,得到立场标注数据集;

S4、机器学习训练:使用所述立场标注数据集,以RoBERTa-Large模型作为基座模型进行训练,得到基于训练的立场词汇标注器,提升标注准确率;

S5、立场标注:通过所述基于训练的立场词汇标注器,完成待分析英语文本的立场标注。

2. 根据权利要求1所述的英语文本立场标注方法,其特征在于,步骤S1包括:

S101、从全球新闻数据库中采集国内外媒体新闻的英语文本语料;

S102、对采集到的文本语料进行重复项筛选,包括通过正则表达式提取标题前缀并分组进行去重,以及执行双规则并行的相似度匹配进行相似文本的删除;

S103、对重复项筛选后的文本进行数据清洗;

S104、通过正则表达式对数据清洗后的文本内容进行分割,分出标题、日期、来源、水印信息、正文几个部分;

S105、采用正则表达式构建分句逻辑,基于英语的标点和引号规则,将文本内容分割成独立的句子,然后采用斯坦福词性标注器Stanford POS Tagger对分割后的句子进行标注,得到每个单词的词性标签;

S106、构建PostgreSQL数据库,分为ID、标题、来源、日期、正文、分句结果、标签;将分割后的内容写入除ID外相应的字段,每条数据有唯一的ID,形成英语文本数据库。

3. 根据权利要求2所述的英语文本立场标注方法,其特征在于,步骤S102所述重复项筛选具体包括:

S102-1、提取文本的标题前缀并分组:通过正则表达式从文本的首行标题中提取前缀;按提取的前缀对文本分组,统计每个分组的文本数量、唯一标题数;仅保留文件数大于1的分组作为候选去重对象;进一步筛选出分组内所有文件标题完全相同且文件数小于等于设定的数量阈值的分组,对筛选出的分组进行后续内容比对;

S102-2、双规则并行的相似度匹配:计算筛选出的分组中各文本内容的完整相似度,若大于等于设定的相似度阈值,则判定为相似文本;若低于设定的相似度阈值,则取前N个字符进行比对,计算子集相似度,若子集相似度大于等于设定的子集相似度阈值,则判定为相似文本;删除匹配到的相似文本,只保留其中一份。

4. 根据权利要求1所述的英语文本立场标注方法,其特征在于,步骤S202包括:

S202-1、根据英语语法中立场动词、立场形容词、立场名词及其引导的补语从句,确定复杂立场词汇的识别类型,包括:

立场动词+to从句;立场动词+that从句;立场形容词+to从句;立场形容词+that从句;立场名词+to从句;立场名词+that从句;

S202-2、设定各识别类型的通用规则,所述通用规则包括:

(1) 词汇定义扩展:将现有立场词汇中定义的立场动词/立场形容词/立场名词的变形形式扩展到对应层级中进行定义扩展;

(2) to/that生效范围的定义:根据to/that分别对应的多种不同的词性标签,定义用于复杂立场词汇判断的词性标签的范围;

(3) 限定规则的定义:所述限定规则包括:根据立场动词/立场形容词/立场名词到to/that之间存在的包括不同词汇、词性标签、标点的语法结构触发不同的判断流程和结果;

S202-3、设定各识别类型的特殊规则,所述特殊规则包括:根据立场动词/立场形容词/立场名词+to/that从句所包含的不符合所述通用规则但目标词仍属于复杂立场词汇的特殊情况,设定对应所述特殊情况的语法结构判断规则。

5. 根据权利要求4所述的英语文本立场标注方法,其特征在于,所述通用规则和特殊规则中,还包括词性标签修正规则,根据目标词的前后文标签,判断是否误标,如果是误标则将误标的词性标签替换为正确的词性标签。

6. 根据权利要求1所述的英语文本立场标注方法,其特征在于,步骤S3包括:

S301、根据立场词汇的定义以及定义中表达立场倾向的子层级的划分,设定立场编码;

S302、根据所述立场词汇标注规则以及立场编码,编程对已包含词性标签的英语文本进行立场标注,得到立场标注数据集。

7. 根据权利要求1所述的英语文本立场标注方法,其特征在于,步骤S4包括:

将所述立场标注数据集划分为训练集、验证集、测试集,将训练集作为RoBERTa-Large模型训练的数据来源,让模型对标注结果进行学习;

使用分词器RobertaTokenizerFast将句子拆成WordPiece子词,并将每个单词的首子词作为一个token,映射到单词对应的标签;随后把标注任务分配给预训练模型类RobertaForTokenClassification,通过交叉熵或多标签损失让模型在大规模语料上学习如何预测规则标签,训练过程中采用梯度累积、混合精度以及学习率warm-up以适应RoBERTa-Large的显存需求;并通过验证集调整模型参数,使用测试集对模型性能进行测试,最终得到训练好的模型作为立场词汇标注器。

8. 一种英语文本立场标注系统,其特征在于,包括:

词性预处理模块:通过数据采集获得英语文本,为英语文本的每个词生成词性标签;

规则构建模块:在所述词性标签的基础上,依据英语句法结构、上下文语义及词汇特性,制定立场词汇标注规则,编写代码得到基于规则的立场词汇标注器;立场词汇标注规则包括:简单立场词汇标注:将情态动词、半情态动词、立场副词作为简单立场词汇,并进行词汇定义扩展;结合目标词的词形与所述词性标签,进行简单立场词汇的判断与标注;复杂立场词汇标注:将引导补语从句的立场动词、立场形容词、立场名词作为复杂立场词汇;汇总复杂立场词汇的识别类型,设定每种识别类型对应的通用规则和特殊规则;结合目标词的

词形与所述词性标签,根据识别类型及其对应规则进行复杂立场词汇的判断与标注;

数据集标注模块:使用所述基于规则的立场词汇标注器,对已包含词性标签的英语文本进行立场标注,得到立场标注数据集;

机器学习训练模块:使用所述立场标注数据集,以RoBERTa-Large作为基座模型进行训练,得到基于训练的立场词汇标注器,提升标注准确率;

立场标注模块:通过所述基于训练的立场词汇标注器,完成待分析英语文本的立场标注。

9.一种可视化检索标注系统,所述可视化检索标注系统通过编程语言开发带数据库可视化检索及标注功能的网页,其特征在于,应用如权利要求1-7任一项所述的英语文本立场标注方法。

一种英语文本立场标注方法及系统

技术领域

[0001] 本发明属于信息技术与自然语言处理的交叉领域,具体涉及一种英语文本立场标注方法及系统。

背景技术

[0002] 英语文本的分析和优化,除了可用于纠正语法错误外,对于文本内容的准确表达、避免表述不当及话语漏洞、提升话语的穿透力、增强沟通效果这些方面都非常重要。其中一项重要的分析和优化就是关于立场表达。运用英语对立场进行恰当表述,能够更精准地传达深层含义,使观点在全球范围内得到准确理解与传播。

[0003] 英语文本立场分析和优化的研究中,对于立场词汇的标注是非常重要的过程。由于立场词汇往往需要结合特定的语法结构来判断,传统研究多采用词性标注器先为文本中每个词分配词性,随后人工手工识别语法关系与立场词。此方式虽然可以保证标注的准确性,但所需的大量人工劳动导致成本高昂,几乎无法在大规模语料上实现可行的立场研究。因此,迫切需要一种能够大批量、精准地识别英语文本中立场词汇的自动化立场标注方法及分析系统。

发明内容

[0004] 本发明的目的在于提供一种英语文本立场标注方法及系统,通过构建英语文本立场标注器,实现对英语文本立场的精准标注。

[0005] 为了实现上述目的,本发明的技术方案是这样的:

[0006] 一种英语文本立场标注方法,包括:

[0007] S1、词性预处理:通过数据采集获得英语文本,为英语文本的每个词生成词性标签;

[0008] S2、规则构建:在所述词性标签的基础上,依据英语句法结构、上下文语义及词汇特性,制定立场词汇标注规则,编写代码得到基于规则的立场词汇标注器;

[0009] S3、数据集标注:使用所述基于规则的立场词汇标注器,对已包含词性标签的英语文本进行立场标注,得到立场标注数据集;

[0010] S4、机器学习训练:使用所述立场标注数据集,以RoBERTa-Large作为基座模型进行训练,得到基于训练的立场词汇标注器,提升标注准确率;

[0011] S5、立场标注:通过所述基于训练的立场词汇标注器,完成待分析英语文本的立场标注。

[0012] 进一步的,步骤S1包括:

[0013] S101、从全球新闻数据库中采集国外主流媒体新闻的英语文本语料和国内主要外宣媒体新闻的英语文本语料;

[0014] S102、对采集到的文本语料进行重复项筛选,包括通过正则表达式提取标题前缀并分组进行去重,以及执行双规则并行的相似度匹配进行相似文本的删除;

- [0015] S103、对重复项筛选后的文本进行数据清洗；
- [0016] S104、通过正则表达式对数据清洗后的文本内容进行分割，分出标题、日期、来源、水印信息、正文几个部分；
- [0017] S105、采用正则表达式构建分句逻辑，基于英语的标点和引号规则，将文本内容分割成独立的句子，然后采用斯坦福词性标注器Stanford POS Tagger对分割后的句子进行标注，得到每个单词的词性标签；
- [0018] S106、构建PostgreSQL数据库，分为ID、标题、来源、日期、正文、分句结果、标签；将分割后的内容写入除ID外相应的字段，每条数据有唯一的ID，形成英语文本数据库。
- [0019] 更进一步的，步骤S102所述重复项筛选具体包括：
- [0020] S102-1、提取文本的标题前缀并分组：通过正则表达式从文本的首行标题中提取前缀；按提取的前缀对文本分组，统计每个分组的文本数量、唯一标题数；仅保留文件数大于1的分组作为候选去重对象；进一步筛选出分组内所有文件标题完全相同且文件数小于等于设定的数量阈值的分组，对筛选出的分组进行后续内容比对；
- [0021] S102-2、双规则并行的相似度匹配：计算筛选出的分组中各文本内容的完整相似度，若大于等于设定的相似度阈值，则判定为相似文本；若低于设定的相似度阈值，则取前N个字符进行比对，计算子集相似度，若子集相似度大于等于设定的子集相似度阈值，则判定为相似文本；删除匹配到的相似文本，只保留其中一份。
- [0022] 更进一步的，步骤S103包括：
- [0023] S103-1、对文本的标题格式调整为规范格式；
- [0024] S103-2、提取文本中的专有名词，形成专有名词词典；
- [0025] S103-3、编写文本格式处理程序对文本的正文内容进行标准化处理；
- [0026] S103-4、通过正则表达式去除包括非法字符、网址链接的无关内容。
- [0027] 进一步的，步骤S2中立场词汇标注规则的制定包括：
- [0028] S201、简单立场词汇标注：将情态动词、半情态动词、立场副词作为简单立场词汇，并进行词汇定义扩展；结合目标词的词形与所述词性标签，进行简单立场词汇的判断与标注；
- [0029] S202、复杂立场词汇标注：将引导补语从句的立场动词、立场形容词、立场名词作为复杂立场词汇；汇总复杂立场词汇的识别类型，设定每种识别类型对应的通用规则和特殊规则；结合目标词的词形与所述词性标签，根据识别类型及其对应规则进行复杂立场词汇的判断与标注。
- [0030] 更进一步的，步骤S201所述词汇定义扩展包括：将现有立场词汇中定义的情态动词、半情态动词、立场副词的变形形式扩展到对应层级中进行定义扩展。
- [0031] 更进一步的，步骤S202包括：
- [0032] S202-1、根据英语语法中立场动词、立场形容词、立场名词及其引导的补语从句，确定复杂立场词汇的识别类型，包括：
- [0033] 立场动词+to从句；立场动词+that从句；立场形容词+to从句；立场形容词+that从句；立场名词+to从句；立场名词+that从句；
- [0034] S202-2、设定各识别类型的通用规则，所述通用规则包括：
- [0035] (1) 词汇定义扩展：将现有立场词汇中定义的立场动词/立场形容词/立场名词的

变形形式扩展到对应层级中进行定义扩展;

[0036] (2) to/that生效范围的定义:根据to/that分别对应的多种不同的词性标签,定义用于复杂立场词汇判断的词性标签的范围;

[0037] (3)限定规则的定义:所述限定规则包括:根据立场动词/立场形容词/立场名词到to/that之间存在的包括不同词汇、词性标签、标点的语法结构触发不同的判断流程和结果;

[0038] S202-3、设定各识别类型的特殊规则,所述特殊规则包括:根据立场动词/立场形容词/立场名词+to/that从句所包含的不符合所述通用规则但目标词仍属于复杂立场词汇的特殊情况,语法结构,设定对应所述特殊情况的语法结构判断规则。

[0039] 再进一步的,所述通用规则和特殊规则中,还包括词性标签修正规则,根据目标词的前后文标签,判断是否误标,如果是误标则将误标的词性标签替换为正确的词性标签。

[0040] 进一步的,步骤S3包括:

[0041] S301、根据立场词汇的定义以及定义中表达立场倾向的子层级的划分,设定立场编码;

[0042] S302、根据所述立场词汇标注规则以及立场编码,编程对已包含词性标签的英语文本进行立场标注,得到立场标注数据集。

[0043] 进一步的,步骤S4包括:

[0044] 将所述立场标注数据集划分为训练集、验证集、测试集,将训练集作为RoBERTa-Large模型训练的数据来源,让模型对标注结果进行学习;

[0045] 使用分词器RobertaTokenizerFast将句子拆成WordPiece子词,并将每个单词的首子词作为一个token,映射到单词对应的标签;随后把该序列标记任务分配给预训练模型类RobertaForTokenClassification,通过交叉熵或多标签损失让模型在大规模语料上学习如何预测规则标签,训练过程中采用梯度累积、混合精度以及学习率warm-up以适应RoBERTa-Large的显存需求;并通过验证集调整模型参数,使用测试集对模型性能进行测试,最终得到训练好的模型作为立场词汇标注器。

[0046] 本发明另一方面还提出了一种英语文本立场标注系统,包括:

[0047] 词性预处理模块:通过数据采集获得英语文本,为英语文本的每个词生成词性标签;

[0048] 规则构建模块:在所述词性标签的基础上,依据英语句法结构、上下文语义及词汇特性,制定立场词汇标注规则,编写代码得到基于规则的立场词汇标注器;

[0049] 数据集标注模块:使用所述基于规则的立场词汇标注器,对已包含词性标签的英语文本进行立场标注,得到立场标注数据集;

[0050] 机器学习训练模块:使用所述立场标注数据集,以RoBERTa-Large作为基座模型进行训练,得到基于训练的立场词汇标注器,提升标注准确率;

[0051] 立场标注模块:通过所述基于训练的立场词汇标注器,完成待分析英语文本的立场标注。

[0052] 本发明还提出了一种可视化检索标注系统,所述可视化检索标注系统通过编程语言开发带数据库可视化检索及标注功能的网页,应用上述英语文本立场标注方法。

[0053] 与现有技术相比,本发明具有如下的有益效果:

[0054] 本发明提出的英语文本立场标注方法、基于训练的英语文本立场标注器及相应系统,能够实现对英语文本立场的精准标注和可视化分析,从而为语言学、国际传播等领域提供可靠的立场研究工具。借助该方法和系统,研究者可以在海量的数据源中,快速高效地识别立场词汇,并结合其在句中出现位置分析句中的立场倾向,从而量化媒体偏见、跟踪公众意见变化,并对跨文化沟通中的立场趋势进行定量分析。该方法和系统将有效推动国内大规模英语文本立场研究的进展,为对外话语体系建设带来有益效果。

附图说明

[0055] 图1为本发明实施例1的方法流程示意图;

[0056] 图2为本发明实施例1的斯坦福标签+立场标签的混合标注结果示意图;

[0057] 图3为本发明实施例3的可视化检索标注系统功能示意图。

具体实施方式

[0058] 需要说明的是,在不冲突的情况下,本发明中的实施例及实施例中的特征可以相互组合。

[0059] 下面结合具体实施例和附图,对本发明进行具体说明。

[0060] 需要声明的是:具体实施例中涉及通过编程语言实现的功能,例如使用编程语言构建正则表达式等,均以Python为例,但并非限定只能使用Python,任何可实现同样功能的编程语言,都属于本发明的保护范围。

[0061] 实施例1:

[0062] 本实施例实施的英语文本立场标注方法,如图1所示,具体包括:

[0063] 1、核心数据采集和词性预处理:

[0064] 1.1 数据采集。从全球新闻数据库采集国外包括英美的主流媒体新闻的英语文本语料、国内主要外宣媒体新闻的英语文本语料(含标题、正文、日期、来源、作者等数据)。

[0065] 1.2 数据筛选。对采集到的原始文本进行重复项筛选,具体流程如下:

[0066] (1) 提取标题前缀并分组。依次执行:通过Python正则表达式PREFIX_SEPARATOR从文件首行标题中提取前缀;按提取的前缀对文件分组,统计每个分组的文件数量、唯一标题数。仅保留文件数大于1的分组作为候选去重对象;进一步筛选出“无子类”(分组内所有文件标题完全相同)且文件数 $\leq$ 数量阈值SIMILARITY_GROUP_MAX_SIZE(本实施例默认数量阈值为10)的分组,仅对这类分组进行后续内容比对;

[0067] (2) 双规则并行的相似度匹配。依次执行:计算文档内容的完整相似度(standard ratio),若大于等于设定的相似度阈值0.8,则判定为相似,标记“Standard”类型;当标准相似度不达标时,取较长内容与较短内容的前N个字符(N=较短内容长度)进行比对,计算子集相似度(subset_ratio),若子集相似度大于等于设定的子集相似度阈值0.9,则判定为相似,标记为Subeset类型;删除匹配到的相似文本,只保留其中一份。

[0068] 1.3 数据清洗。包括:标题格式调整;提取专有名词,形成专有名词词典(保护格式);通过Python编写文本格式处理程序对正文内容大小写、标点符号、常见缩写形式、句首字母大写等进行标准化处理;应用NLTK和Python正则表达式,对文本进行清洗,去除非法字符、网址链接等无关内容。

[0069] 1.4内容分割。通过正则表达式对文本内容进行分割,分出标题、日期、来源、水印信息、正文几个部分。

[0070] 1.5文本预标注。编写python分句文件text_utils.py,采用Python正则表达式构建完整的分句逻辑,考虑英语的标点和引号规则(尤指现代英语),将文本内容分割成独立的句子。然后采用斯坦福词性标注器Stanford POS Tagger对分割后的句子进行标注,得到每个单词的词性标签。

[0071] 1.6 数据入库。构建PostgreSQL数据库,分为ID、标题、来源、日期、正文、分句结果、标签;将分割后的内容写入除ID外相应的字段,每条数据有唯一的ID,形成英语文本数据库 α 。

[0072] 2、制定立场词汇识别规则。

[0073] 本实施例中以英语的立场词汇表作为主要的立场词汇来源,所述立场词汇表可采用美国著名语言学家Douglas Biber于2006年发表的书籍《University Language: A corpus-based study of spoken and written registers》第五章93页中的立场词汇表,也可采用其他来源的通用的立场词汇表。Biber的立场词汇表中将立场词汇分为了3个类别,分别是:

[0074] ①情态动词Modal verbs与半情态动词semi-modal verbs;

[0075] ②立场副词Stance Adverbs ;

[0076] ③引导补语从句的立场动词、立场形容词、立场名词Complement clauses controlled by stance verbs, adjectives, or nouns。

[0077] 其中①和②类中词汇的识别不需要复杂的语法结构,只需要结合词形与词性标签即可判断,因此将其命名为简单立场词汇simple_stance_words;③中的词汇需要结合复杂的语法规则进行判断,因此将其命名为复杂立场词汇complex_stance_words。对英语语法中的引导补语从句的语法结构进行分析,汇总出第③类立场词汇涉及的识别类型主要分为以下6种:

[0078] 1) 立场动词+to从句;

[0079] 2) 立场动词+that从句;

[0080] 3) 立场形容词+to从句;

[0081] 4) 立场形容词+that从句;

[0082] 5) 立场名词+to从句;

[0083] 6) 立场名词+that从句;

[0084] 其中to从句是指不定式从句,that从句是指从属连词that引导的补语从句。

[0085] 根据上述特性分别制定简单立场词汇simple_stance_words与复杂立场词汇complex_stance_words的识别规则。

[0086] 2.1 简单立场词汇simple_stance_words识别规则:

[0087] 简单立场词汇不涉及复杂的语法规则,以词形匹配的方式就可以保证90%以上的准确率。本实施例中对于simple_stance_words的识别主要采取词形匹配+斯坦福词性标签结合的方式,识别准确率可达98%以上,其主要取决于斯坦福词性标注器的词性识别准确率,因为词形匹配通常不会出错,下面是具体的规则介绍。

[0088] 2.1.1情态动词和半情态动词(Modal and semi-modal verbs):

[0089] 首先进行词汇定义扩展,将情态动词和半情态动词的变形形式扩展到对应层级中,说明如下:

[0090] 部分情态动词存在立场变形,例如“could”是情态动词,它的关联形式“couldn’t”和“could not”也属于立场词汇。对于该类包含变体的词汇,以“could0”这样的形式作为基础形式,定义词汇列表包含各种变体形式,参考如下形式(仅列出部分):

[0091] could0 = ["could", "could not", "couldn't"];

[0092] may0 = ["may", "may not"];

[0093] might0 = ["might", "might not", "mightn't"];

[0094] must0 = ["must", "must not", "mustn't"];

[0095] should0 = ["should", "should not", "shouldn't"];

[0096] 同时,需要同时定义层级结构,所述层级结构基于语言学家Douglas Biber给出的立场词汇的层级,如情态动词和半情态动词的层级为:

[0097] “1.Modal and semi-modal verbs(顶层:情态动词和半情态动词)

[0098] 1.1.possibility/permission/ability(二层:语义为可能性/许可/能力)

[0099] 1.2.necessity/obligation(二层:语义为必要性/义务)

[0100] 1.3.prediction/volition(二层:语义为预测/意愿)”;

[0101] 则词汇定义扩展后定义层级的数据结构参考如下形式(仅列出部分):

[0102] “Modal and semi-modal verbs”: {

[0103] “possibility/permission/ability”: {

[0104] “words”: ["can", "cannot", "can't",

[0105] “could”, “could not”, “couldn't”,

[0106] “may”, “may not”,

[0107] “might”, “might not”, “mightn't”],

[0108] “subcategories”: {}

[0109] }

[0110] } ;

[0111] 上述数据结构表明层级结构包括:

[0112] 顶层Modal and semi-modal verbs,表示核心主题为情态动词与半情态动词;

[0113] 二层possibility/permission/ability,表示语义层:可能性/许可/能力;

[0114] 子层word,表示语义层下的词汇(包括词汇变体);

[0115] 子层subcategories,表示语义层下的子类别(当前为空)。

[0116] 层级结构的设置,用于后续立场编码的设置以及立场倾向的判断。

[0117] 识别时如果是单个词汇,如“could”,需要同时满足以下三个条件:①词形与该分类中的立场词汇一致,②标签为MD(斯坦福词性标注器的情态动词标签),③属于层级结构中的对应类别,可识别为简单立场词汇。

[0118] 如果是词组,如“may not”,则只需满足词形一致以及属于层级结构中的类别,即可识别为简单立场词汇。

[0119] 2.1.2立场副词(Stance Adverbs)

[0120] 立场副词不存在变形,因此无需定义词汇变体,只需定义层级结构,所述层级结构

基于语言学家Douglas Biber给出的立场词汇的层级。

[0121] 参考如下形式(仅列出部分):

[0122] "Stance adverbs": {

[0123] "Epistemic": {

[0124] "words": [],

[0125] "subcategories": {

[0126] "Certainty": ["actually", "always", "certainly", "definitely", "indeed", "inevitably", "in fact", "never", "of course", "obviously", "really", "undoubtedly", "without doubt", "no doubt"],

[0127] "Likelihood": ["apparently", "evidently", "kind of", "in most cases", "in most instances", "perhaps", "possibly", "predictably", "probably", "roughly", "sort of", "maybe"]

[0128] }

[0129] }

[0130] };

[0131] 上述数据结构表明层级结构包括:

[0132] 顶层Stance adverbs,表示核心主题为立场副词;

[0133] 二层Epistemic,表示语义层:认知类;

[0134] 子层word,表示认知类语义层下的词汇变体,由于不存在变形,所以为空;

[0135] 子层subcategories,表示语义范畴下的子类别,分别包括表示确定性的子类别Certainty、表示可能性的子类别Likelihood,以及各子类别的词汇。

[0136] 识别时如果是单个词汇,如“actually”,需要满足以下三个条件:①词形一致,②标签为RB(斯坦福标注其的副词标签),③属于层级结构中的对应类别,可识别为简单立场词汇。

[0137] 如果是词组形式出现,如“in fact”,则只需要满足词性一致和属于层级结构中的对应类别即可识别为简单立场词汇。

[0138] 2.2复杂立场词汇complex_stance_words识别规则:

[0139] 复杂立场词汇涉及复杂的语法结构以及词汇变形,需要多种方式结合进行判断。本实施例中对于复杂立场词汇complex_stance_words的识别采取以下几个方式结合:①词形匹配 ②斯坦福词性标注 ③基础词性纠正 ④识别规则编写 ⑤特殊情况排除。经过大范围测试,该类型的立场词汇识别准确率在95%左右,错误来源主要有以下几种情况:①基础词性标注错误 ②规则无法完全覆盖 ③特殊标点符号(如破折号、连接符)导致规则查找中断 ④立场词汇以专有名词/词组形式出现 ⑤距离过长导致查找中断。下面是具体的规则介绍:

[0140] 2.2.1 立场动词+to从句。

[0141] 1) 通用规则:

[0142] ①定义立场动词。Biber的立场词汇表中仅给出了立场动词的原形,但实际句子中立场动词变形包括:原形、第三人称单数、现在分词、过去式、过去分词这5种形式,因此需要定义完整的词汇列表,同样以类似“conclude0”这样的形式列出完整的词汇列表,参考如下

形式(仅列出部分):

[0143] conclude0 = ["conclude", "concludes", "concluding", "concluded"];

[0144] find0 = ["find", "finds", "finding", "found"];

[0145] 需要同时定义层级结构,所述层级结构同样基于语言学家Douglas Biber给出的立场词汇的层级,定义方式如前面层级结构所示。

[0146] 由于部分立场动词如“wish”既可以是动词也可以是名词,部分立场动词变形如“prepared”既可以是动词过去式也可以是形容词,因此需要通过标签+规则的形式确保句中的词汇是真正的立场动词,具体方式如下:

[0147] 确保立场动词标签是“V”开头。斯坦福的词性标签有关动词的一共有6种,全部以V开头,具体如表1所示:

[0148] 表1:动词标签类型

[0149]	标签	含义
	VB	动词原形
	VBP	非第三人称单数
	VBZ	第三人称单数
	VBG	动名词/现在分词
	VBD	动词过去式
	VCN	过去分词

[0150] VBG和VCN可能存在形容词词性,如“a loving_VBG person”和“a prepared_VCN meal”,斯坦福标注误判的概率较高,因此为了确保准确率,将主要判断标签范围收紧到VB/VBP/VBZ/VBD四类。

[0151] 将部分V开头但实际是形容词的(斯坦福误标)的词汇转为JJ标签(形容词),具体判断逻辑为:检查目标词左侧紧邻的标签是否属于['PRP\$', 'POS', 'JJ']或紧邻词汇是否为['a', 'an', 'the'],如果满足其中一种,则忽略原始标签,将标签替换为JJ。

[0152] ②定义“to”生效范围。to从句指不定式从句,首先用斯坦福T0标签(不定式)做一次判断。为了避免斯坦福将“to”作介词的情况(标签为IN)误判为不定式T0,需要进一步收窄T0标签的生效范围。如果T0右侧紧邻的标签是DT(限定词),则将T0替换为IN(介词/连词标签);同时为了纠正某些情况下“to”应该被标记为T0标签但却被标记成为IN,根据如下规则进行检查:

[0153] a. “to”的标签已经是T0,则直接生效;

[0154] b. 如果不是T0,则判断其右侧紧邻的标签是否是VB(动词原形),如果是,则忽略之前的标签,直接将to的标签替换为T0。

[0155] 其余进入判断流程的T0标签右侧必须满足如下两种情况才认为有效:

[0156] a. 其右侧紧邻的标签是VB或VBP(中间没有除了引号之外的标点符号);

[0157] b.其右侧第一个位置是RB(副词),第二个位置是VB或VBP,且中间没有除了引号之外的标点符号。

[0158] ③定义限定规则。由于立场动词+to从句中,目标词右侧并不总是紧邻不定式“to”,因此需要根据定义目标词到T0之间的限定规则,根据立场动词到to之间存在的包括不同词汇、词性标签、标点的语法结构触发不同的判断流程和结果。例如:若目标词与 T0之间存在以V开头或属于WP/WRB/WP\$/WDT 的词性标签,则触发阻断,对该目标词的识别结果返回为“空”;若目标词为 find/finds/finding/found,且右侧紧跟it,则对该目标词的识别结果返回为“空”,等等;共同形成立场动词+to从句限定规则汇总。

[0159] 2) 特殊规则:

[0160] 立场动词+to从句有一种可以省略“to”的特殊情况,即该词是“help”系列,构成 help (sb.) (to) do的结构,包括[“help”, “helps”, “helping”, “helped”],此时无法再依赖T0标签进行判断,需要特殊规则辅助,具体特殊规则是:

[0161] ①目标词必须是V开头(限定为动词标签);

[0162] ②从目标词向右查找至多5个位置,检查是否存在VB或VBP标签(动词原形),如果没有找到则直接跳过,如果找到则进行后续判断;

[0163] ③检查目标词右侧是否紧邻VB或VBP,且无除引号外的其他标点符号,如果满足,则认为生效,可判断识别目标词为立场动词;

[0164] ④检查VB或VBP左侧紧邻的是否为PRP(人称代词)或N开头的标签(名词),如果是,则认为生效,可判断识别目标词为立场动词。

[0165] 2.2.2 立场动词+that从句。

[0166] 1) 通用规则:

[0167] ①定义立场动词。2.2.1已经列出过程,这里不再赘述;

[0168] ②定义“that”生效范围。由于that能同时作为指示代词、限定词、从属连词和关系代词。而that从句需要的是类型是从属连词,因此只有标签为IN的that认为生效,可以进入判断流程。

[0169] ③定义限定规则。立场动词+that从句中,目标词右侧通常并不紧邻“that”,因此需要定义目标词与that_IN之间的限定规则,例如在目标词与 that 之间出现以 VB 开头且不为 VBG/VBN 的标签,则触发阻断,对该目标词的识别结果返回为“空”,等等;共同形成立场动词+that从句限定规则汇总。

[0170] 2) 特殊规则:

[0171] 立场动词+that从句包含以下两种特殊情况:①that省略 ②其他等同于that省略的情况,该类情况在原有标签后面添加[THTAD](that省略)标签,构成组合标签,例如“knows_VBZ[THATD]”这种形式,标识其为that从句。

[0172] 2.2.3 立场形容词+to从句。

[0173] 1) 通用规则:

[0174] ①定义立场形容词。形容词(JJ)虽然有比较级(JJR)和最高级(JJS),但是后面不能直接跟不定式或从属连词that,因此立场形容词只考虑其基本形式,同时需要定义立场形容词的层级结构,与立场动词类似,这里不再赘述。

[0175] 部分形容词尽管被斯坦福词性标注器标记为JJ,但并不适用于立场形容词判断,

需要将这些词汇的标签转为ADJ(普通形容词),在通用规则中也设置了针对这种情况的具体规则,例如:目标词左侧 2 个位置内存在以下任一内容:词性标签为PRP\$(物主代词标签)或POS(所有格标签),对应的词本身为限定词a/an/the,则将目标词的原有词性标签JJ替换为通用形容词标签ADJ,不参与立场形容词判断;等等。通用规则中设置了JJ转ADJ规则汇总。

[0176] 部分被误标为VBN的单词实际上的作用是形容词,具体的判断方法是:检查VBN左侧3个位置内是否存在be动词,如果存在,且分类正确,则同样认为是立场形容词。

[0177] 因此参与判断的立场形容词包含:

[0178] a. 初始被标记为JJ的形容词,且不符合ADJ转换规则;

[0179] b. 初始标记是V开头,但通过2.2.1通用规则第①点中提到的转换规则转换后得到的JJ;

[0180] c. 符合规则的VBN。

[0181] ②定义“to”生效范围。与立场动词+to一致,不再赘述。

[0182] ③定义限定规则。由于立场形容词+to从句中,目标词右侧并不总是紧邻不定式“to”,因此需要定义目标词到T0之间的限定规则,例如目标词与 T0 之间出现以 V 或 N 开头的标签,或 PRP,则触发阻断,对该目标词的识别结果返回为“空”,等等;共同形成立场形容词+to从句限定规则汇总。

[0183] 2) 特殊规则:

[0184] ①“better”。当需要判断的词为better时,需要判断其右侧是否紧邻JJ或ADJ标签,因为可能出现“better improve”这样的形式,此时better容易被标为JJ,但实际上是副词。因此遇到这种情况时,不认为better是立场形容词。

[0185] ②“as soon as possible”。当possible出现在该词组中时,其不表达立场功能,而是一种可能性,因此该情况中的“possible”不认为是立场形容词。

[0186] 2.2.4 立场形容词+that从句。

[0187] 1) 通用规则:

[0188] ①定义立场形容词。2.2.3已经列出,不再赘述。

[0189] ②定义“that”生效范围。与立场动词+that一致,不再赘述。

[0190] ③定义限定规则。立场形容词+that从句中,目标词右侧通常并不紧邻“that”,因此需要定义目标词与that_IN之间的限定规则,例如目标词右侧紧邻标签以N开头,则触发阻断,对该目标词的识别结果返回为“空”,等等;共同形成立场形容词+ that从句限定规则汇总。

[0191] 2) 特殊规则:

[0192] 立场形容词+that也存在that省略的情况,例如目标词左侧1-2个位置存在介词(preposition集合),则跳过,不标记[THATD],不视为属于that从句,等等;共同构成立场形容词省略that规则汇总。

[0193] 2.2.5 立场名词+to从句。

[0194] 1) 通用规则:

[0195] ①定义立场名词。名词包含单复数,因此需要定义一个原始层级,例如“reason0”,其中包含[“reason”, “reasons”],同时需要定义立场名词的层级结构,与立场动词类似,

这里不再赘述。

[0196] 某些立场名词如“hope”既可以作为名词,又可以作为动词,因此需要以标签N开头限定其为名词。另外,这类作名词使用时经常会被误标为VBG或VBN,因此需要指定规则纠正:①检查在stance名词集合中的词汇原始标签是否为VBG/VBN,且左侧紧邻的是be集合中的词汇,如果是则执行第二步;②检查其左侧紧邻的标签是否为DT/POS/PRP\$/JJ/N开头/V开头/在prep列表中,如果是,则将其原始标签替换为NN。

[0197] 因此参与判断的立场名词包括:①原始标签为N开头;②VBG/VBN替换后得到的NN。

[0198] ②定义“to”生效范围。与立场动词+to一致,不再赘述。

[0199] ③定义限定规则。由于立场形容词+to从句中,目标词右侧并不总是紧邻不定式“to”,因此需要定义目标词到TO之间的限定规则,例如在目标词与 TO 之间出现以 VB 开头且不为 VBG/VBN 的标签,则触发阻断,对该目标词的识别结果返回为“空”,等等;共同形成立场名词+to从句限定规则汇总。

[0200] 2) 特殊规则:

[0201] 某些立场名词可能在专有名词词组中出现,此时不表达立场,即使符合语法规则也不认为是立场名词,例如:①result出现在as a result中;②news出现在news agency或news conference中;③fact出现在in fact中;④report出现在work report中;⑤requirement出现在reserve requirement中。

[0202] 当立场名词是['reason', 'reasons']或['report', 'reports', 'statement', 'statements'],需要特殊排除规则,具体是:

[0203] ①reason/reasons右侧不能紧邻why,该情况视为why引导的从句,不属于立场动词+to从句类型。

[0204] ②report/reports/statement/statements左侧4个位置内不能有in/at,否则report认为属于介词短语,不是立场名词。

[0205] 2.2.6 立场名词+that从句。

[0206] 1) 通用规则:

[0207] ①定义立场名词。2.2.5已经列出,不再赘述。

[0208] ②定义“that”生效范围。与立场动词that稍微不同,因为立场名词+that句型中that经常被标记为WDT(wh-限定词),因此将that标签范围扩展到IN/WDT。

[0209] ③定义限定规则。立场名词+that从句中,目标词右侧通常并不紧邻“that”,因此需要定义目标词与that_IN/WDT之间的限定规则,例如在目标词与 that 之间出现以 V 开头的标签,则触发阻断,对该目标词的识别结果返回为“空”,等等;共同形成立场名词+that从句限定规则汇总。

[0210] 2) 特殊规则:

[0211] 立场名词+that也存在that省略的情况,具体规则例如目标词为 reason/reasons,右侧紧邻词为 why,则跳过 THATD 标记,等等;共同构成立场名词省略that规则汇总。

[0212] 3、数据集标注。

[0213] 3.1.1 标签命名:

[0214] 首先需要给不同层级的每一类立场词汇 (包含3个大类中具体的子类) 赋予标签命名, 如表2所示为部分标签:

[0215] 表2:立场编码表

[0216]

序号	立场分类	层级命名	标签
1	立场情态(可能/允许/能力)	possibility/permission/ability	POSMD
2	立场情态(必要/义务)	necessity/obligation	NESMD
3	立场情态(预测/意志)	prediction/volition	PRSMD
4	立场副词	Stance adverbs: Epistemic (Certainty)	SDEC
5	立场副词	Stance adverbs: Epistemic (Likelihood)	SDEL
6	that 补语从句-立场动词(认知-确定)	that-complement clauses controlled by Epistemic Verbs- Certainty	CCTH-SVEC
7	that 补语从句-立场动词(认知-可能)	that-complement clauses controlled by Epistemic Verbs- Likelihood	CCTH-SVEL
8	To 补语从句-立场动词(可能)	to-complement clauses controlled by Probability (likelihood) verbs	CCTO-SVP
9	To 补语从句-立场动词(观点)	to-complement clauses controlled by Cognition/perception verbs (likelihood)	CCTO-SVC

[0217] 3.1.2 立场标注器路由文件集成:

[0218] 使用Python编程语言将上述内容集成为可调用的立场标注器路由文件, 命名为 Stance Tagger 1.0。具体流程如下:

[0219] ①调用Stanford POS Tagger对数据库 α 中指定ID的文章正文进行分句标注, 获取斯坦福原始标注结果;

[0220] ②应用立场规则对相同文章进行二次标注, 获取对应分类中的立场词汇;

[0221] ③将对应分类中立场词汇的斯坦福词性标签替换为立场标签, 其余非立场词汇标签保持不变, 最终获得斯坦福标签+立场标签的混合标注结果, 形式可参考图2所示, 蓝色标签为词性标签, 红色标签为立场标签。

[0222] 3.1.3 测试规则准确率:

[0223] 为了便于测试基于规则标注的准确率,本实施例基于Python编程语言开发了立场标注可视化系统进行测试;最终基于上述规则的立场词汇标注,经测试平均准确率约为95%。

[0224] 3.1.4立场标注数据集;

[0225] 应用立场标注器路由文件Stance Tagger 1.0对数据库 α 所有文章的正文部分进行分句标注,得到每个句子的基础词性与立场标签混合标注结果,格式例如“I_PRP will_PRSM continue_VB to_TO do_VB that_DT.”。

[0226] 所有句子标注完成后,形成标准JSON格式的立场标注数据集 β ,其中包含句子、词汇标签、时间戳、句子索引、新闻日期、新闻来源等信息。

[0227] 4、机器学习训练。

[0228] (1)RoBERTa介绍

[0229] 本实施例使用RoBERTa-Large (RoBERTa模型的最大参数版本) 作为基座模型进行标注训练。

[0230] RoBERTa是Facebook AI Research推出的一种基于BERT优化的预训练模型,在BERT的基础上,通过对预训练流程的优化,显著提升了模型性能。RoBERTa 通过在大规模语料库上进行预训练,学习到了丰富的语言知识和语义表示,能够准确理解文本的含义,捕捉文本中的语法、语义和上下文信息,由于预训练阶段已经积累了大量的通用语言知识,所以在微调时,即使只有少量的特定任务标注数据,模型也能利用这些数据进行有效的学习和调整,从而获得较为准确的标注结果。

[0231] (2) 模型训练

[0232] ①应用所述立场标注数据集 β ,将数据集分割为三部分:80%为训练集A,10%为A的验证集,10%为测试集B。验证集用于检测模型每个训练轮次的学习效果,方便对参数进行调优。

[0233] ② 将训练集A作为RoBERTa-Large模型训练的数据来源,让模型对标注结果进行学习。使用RobertaTokenizerFast 将句子拆成WordPiece子词,并把每个token(仅首子词)映射到对应的标签,后续子词被设为忽略(-100)。随后把该序列标记任务分配给RobertaForTokenClassification,通过交叉熵让模型在大规模语料上学习如何预测规则标签(每个token对应单一标签),训练过程中采用梯度累积、混合精度以及学习率warm-up以适应 RoBERTa-Large的显存需求,并在验证集上检验每轮epoch的损失率、准确率和F1等指标,以便调整模型参数。最终,模型能够针对测试集中的句子生成与预期一致的标注结果,实现从已有知识向模型的传递。

[0234] ③使用测试集B(清除已有标签)对模型性能进行测试,用微调好的RoBERTa-Large进行一次完整推理,得到每个token的预测标签。随后与已有标注结果进行对比,统计总体准确率、宏/微平均F1、以及每个标签的精确率与召回率,判断模型在立场标注方面的迁移效果,针对识别准确率较低的标签再次投放新的数据集训练,直至模型标注准确率达到98%以上,认为该标注模型已训练完毕,作为立场词汇标注器,命名为Stance Tagger 2.0。

[0235] 5、立场标注。

[0236] 通过所述立场词汇标注器,完成待分析英语文本的立场标注。

[0237] 本实施例实施的方法,可以构建英语文本立场标注器,快速高效地识别立场词汇,

并结合其在句中出现位置分析句中的立场倾向,实现对英语文本立场的精准标注。

[0238] 实施例2:

[0239] 本实施例提出一种英语文本立场标注系统,包括:

[0240] 词性预处理模块:通过数据采集获得英语文本,为英语文本的每个词生成词性标签;

[0241] 规则构建模块:在所述词性标签的基础上,依据英语句法结构、上下文语义及词汇特性,制定立场词汇标注规则,编写代码得到基于规则的立场词汇标注器;

[0242] 数据集标注模块:使用所述基于规则的立场词汇标注器,对已包含词性标签的英语文本进行立场标注,得到立场标注数据集;

[0243] 机器学习训练模块:使用所述立场标注数据集,以RoBERTa-Large作为基座模型进行训练,得到基于训练的立场词汇标注器,进一步提升标注准确率;

[0244] 立场标注模块:通过所述基于训练的立场词汇标注器,完成待分析英语文本的立场标注。

[0245] 其中,词性预处理模块包括:

[0246] 从全球新闻数据库中采集国外主流媒体新闻的英语文本语料和国内主要外宣媒体新闻的英语文本语料;对采集到的文本语料进行重复项筛选,包括通过正则表达式提取标题前缀并分组进行去重,以及执行双规则并行的相似度匹配进行相似文本的删除;对重复项筛选后的文本进行数据清洗;通过正则表达式对数据清洗后的文本内容进行分割,分出标题、日期、来源、水印信息、正文几个部分;采用正则表达式构建分句逻辑,基于英语的标点和引号规则,将文本内容分割成独立的句子,然后采用斯坦福词性标注器Stanford POS Tagger对分割后的句子进行标注,得到每个单词的词性标签;构建PostgreSQL数据库,分为ID、标题、来源、日期、正文、分句结果、标签;将分割后的内容写入除ID外相应的字段,每条数据有唯一的ID,形成英语文本数据库。

[0247] 所述重复项筛选具体包括:

[0248] 提取文本的标题前缀并分组:通过正则表达式从文本的首行标题中提取前缀;按提取的前缀对文本分组,统计每个分组的文本数量、唯一标题数;仅保留文件数大于1的分组作为候选去重对象;进一步筛选出分组内所有文件标题完全相同且文件数小于等于设定的数量阈值的分组,对筛选出的分组进行后续内容比对;双规则并行的相似度匹配:计算筛选出的分组中各文本内容的完整相似度,若大于等于设定的相似度阈值,则判定为相似文本;若低于设定的相似度阈值,则取前N个字符进行比对,计算子集相似度,若子集相似度大于等于设定的子集相似度阈值,则判定为相似文本;删除匹配到的相似文本,只保留其中一份。

[0249] 数据清洗包括:

[0250] 对文本的标题格式调整为规范格式;提取文本中的专有名词,形成专有名词词典;编写文本格式处理程序对文本的正文内容进行标准化处理;通过正则表达式去除包括非法字符、网址链接的无关内容。

[0251] 规则构建模块包括:

[0252] 简单立场词汇标注单元:将情态动词、半情态动词、立场副词作为简单立场词汇,并进行词汇定义扩展;结合目标词的词形与所述词性标签,进行简单立场词汇的判断与标

注;

[0253] 复杂立场词汇标注单元:将引导补语从句的立场动词、立场形容词、立场名词作为复杂立场词汇;汇总复杂立场词汇的识别类型,设定每种识别类型对应的通用规则和特殊规则;结合目标词的词形与所述词性标签,根据识别类型及其对应规则进行复杂立场词汇的判断与标注。

[0254] 复杂立场词汇标注单元包括:

[0255] 根据英语语法中立场动词、立场形容词、立场名词及其引导的补语从句,确定复杂立场词汇的识别类型,包括:立场动词+to从句;立场动词+that从句;立场形容词+to从句;立场形容词+that从句;立场名词+to从句;立场名词+that从句;

[0256] 设定各识别类型的通用规则,所述通用规则包括:词汇定义扩展:将现有立场词汇中定义的立场动词/立场形容词/立场名词的变形形式扩展到对应层级中进行定义扩展;to/that生效范围的定义:根据to/that分别对应的多种不同的词性标签,定义用于复杂立场词汇判断的词性标签的范围;限定规则的定义:所述限定规则包括:根据立场动词/立场形容词/立场名词到to/that之间存在的包括不同词汇、词性标签、标点的语法结构触发不同的判断流程和结果;

[0257] 设定各识别类型的特殊规则,所述特殊规则包括:根据立场动词/立场形容词/立场名词+to/that从句所包含的不符合所述通用规则但目标词仍属于复杂立场词汇的特殊情况,语法结构,设定对应所述特殊情况的语法结构判断规则。

[0258] 所述通用规则和特殊规则中,还包括词性标签修正规则,根据目标词的前后文标签,判断是否误标,如果是误标则将误标的词性标签替换为正确的词性标签。

[0259] 数据集标注模块包括:

[0260] 根据立场词汇的定义以及定义中表达立场倾向的子层级的划分,设定立场编码;

[0261] 根据所述立场词汇标注规则以及立场编码,编程对已包含词性标签的英语文本进行立场标注,得到立场标注数据集。

[0262] 机器学习训练模块包括:

[0263] 将所述立场标注数据集划分为训练集、验证集、测试集,将训练集作为RoBERTa-Large模型训练的数据来源,让模型对标注结果进行学习;

[0264] 使用分词器RobertaTokenizerFast将句子拆成WordPiece子词,并将每个单词的首子词作为一个token,映射到单词对应的标签;随后把该序列标记任务分配给预训练模型类RobertaForTokenClassification,通过交叉熵或多标签损失让模型在大规模语料上学习如何预测规则标签,训练过程中采用梯度累积、混合精度以及学习率warm-up以适应RoBERTa-Large的显存需求;并通过验证集调整模型参数,使用测试集对模型性能进行测试,最终得到训练好的模型作为立场词汇标注器。

[0265] 本实施例提出的英语文本立场标注系统,能够实现实施例1中的英语文本立场标注方法,具有与实施例1相同的有益效果。

[0266] 实施例3:

[0267] 本实施例提出一种可视化检索标注系统,应用实施例1所述的英语文本立场标注方法。

[0268] 所述可视化检索标注系统通过编程语言开发带数据库可视化检索及标注功能的

网页,其具体功能如图3所示,包括:

[0269] 一、后端:

[0270] 1、数据:

[0271] 首先进行英语文本数据采集,然后进行数据标准化处理,标准化处理后的数据构建英语文本数据库。

[0272] 上数据处理过程与实施例1中一致。

[0273] 2、制定实施例1中所述的立场标注规则。

[0274] 3、构建实施例1中所述的基于规则的立场词汇标注器。

[0275] 4、进行机器学习模拟训练。

[0276] 5、通过上述训练得到基于训练的立场词汇标注器。

[0277] 二、前端:

[0278] 设置可视化的用户交互界面,用户交互界面提供了数据库检索平台来检索英语文本数据库,还提供了立场分析系统,调用基于训练的立场词汇标注器进行立场词汇标注及分析。

[0279] 本实施例提出的可视化检索标注系统,能够实现实施例1中的英语文本立场标注方法,具有与实施例1相同的有益效果。

[0280] 以上所述实施例仅是本发明的优选实施方式,只是用于帮助理解本申请的方法及其核心思想,本发明的保护范围并不仅局限于上述实施例,凡属于本发明思路下的技术方案均属于本发明的保护范围。应当指出,对于本技术领域的普通技术人员来说,在不脱离本发明原理前提下的若干改进和润饰,这些改进和润饰也应视为本发明的保护范围。




图1



图2




图3